

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.89:330.4

Отчет об исследовательском проекте на тему:
Эмпирическое исследование и визуализация ключевых предикторов успеха
предпринимательских инициатив
(промежуточный, этап 1)

Выполнил студент:

группы #БПМИ232, 3 курса Бородатов Егор Олегович

Принял руководитель проекта:

Иванов Андрей Александрович

Доцент

Базовая кафедра Т-Банка

16	Содержание	
17	Аннотация	4
18	1 Основные термины и определения	5
19	2 Введение	6
20	2.1 Актуальность работы	6
21	2.2 Цель	7
22	2.3 Объект исследования	7
23	2.4 Предмет исследования	8
24	2.5 Методы исследования	8
25	2.5.1 Методы предобработки данных	8
26	2.5.2 Разведочный анализ данных (EDA)	8
27	2.5.3 Статистический анализ и прогнозное моделирование	9
28	2.5.4 Анализ динамики	9
29	2.5.5 Инструменты визуализации	9
30	2.6 Задачи	9
31	2.7 План работы	10
32	3 Обзор литературы	13
33	3.1 Определение результата	13
34	3.2 Характеристики компаний и прогнозный анализ	13
35	3.3 Публичные сведения и текстовые признаки	14
36	3.4 Время наблюдения и проверка качества	15
37	4 Описание данных	16
38	4.1 Источники и даты наблюдения	16
39	4.2 Поля исходных файлов	17
40	4.3 Формирование исследуемой группы и производные поля	19
41	4.4 Последующий статус и границы наблюдения	21
42	4.5 Проверки и воспроизводимость	21
43	5 Разведочный анализ данных	22
44	5.1 Формирование исследуемой совокупности	22
45	5.2 Полнота исходных характеристик	22

46	5.3	Последующие статусы и наблюдаемый показатель успеха	23
47	5.4	Годы набора и доступность последующих статусов	24
48	5.5	Распределения числовых характеристик	26
49	5.6	Исходный размер команды в группах последующего статуса	27
50	5.7	Связи между числовыми признаками	28
51	5.8	Географический состав	28
52	5.9	Тематические теги исходных карточек	30
53	6	Методология прогнозного анализа	33
54	6.1	Задача и границы первого эксперимента	33
55	6.2	Сравниваемые модели и обработка признаков	33
56	6.3	Вложенная перекрёстная проверка	34
57	6.4	Метрики и дополнительная полезность признаков	36
58	6.5	Объяснение прогнозов с помощью SHAP	37
59	7	Прогностическая полезность характеристик команды	38
60	7.1	Качество прогноза в основной схеме	38
61	7.2	Дополнительная информация о команде	39
62	7.3	Проверка с разделением наборов YC	41
63	7.4	Вероятности и наблюдаемые частоты	43
64	7.5	Вклад признаков в прогнозы CatBoost	45
65	7.6	Выводы первого эксперимента	46
66	8	Корреляционный анализ	47
67	9	Анализ динамики (2023–2025)	48
68	9.1	Матрица переходов статусов	48
69	9.2	Динамика размера команды	49
70	10	Выводы и рекомендации	50
71	10.1	Основные результаты	50
72	10.2	Методологический вклад	51
73	10.3	Ограничения исследования	51
74	10.4	Рекомендации	51
75		Список литературы	53

76 Аннотация (TODO переделать)

77 Курсовой проект посвящен эмпирическому исследованию факторов, влияющих на
78 успех предпринимательских инициатив (стартапов), с применением методов визуальной ана-
79 литики и статистического анализа. Актуальность работы обусловлена высокой степенью
80 неопределенности венчурного рынка и необходимостью выявления закономерностей, связан-
81 ных с успехом или провалом стартапов, а также малым количеством работ, основанных на
82 точных данных, в данной сфере.

83 Целью работы является выявление и визуализация ключевых предикторов успеха
84 стартапов на основе данных акселератора Y Combinator. В ходе исследования был прове-
85 ден сбор и предобработка данных из открытых источников (Kaggle), выполнен разведочный
86 анализ данных (EDA), проведен сравнительный анализ групп успешных и неуспешных стар-
87 тапов, а также корреляционный анализ числовых признаков. Для проверки статистических
88 гипотез использовался критерий Манна-Уитни.

89 Важной особенностью работы является контроль по году батча (когорте) при проверке
90 гипотез, что позволяет избежать ошибки выжившего. Вместо наивного сравнения по возрас-
91 ту компании или размеру команды (которые растут *после* успеха), анализ сфокусирован
92 на характеристиках, известных на момент входа в акселератор: тип команды основателей,
93 отрасль, сезон батча, лаконичность описания, количество тегов и география.

94 Результаты работы показывают, что наиболее значимыми предикторами успеха явля-
95 ются наличие команды основателей (а не основателя-одиночки), принадлежность к отрасли
96 B2B, стадия развития компании, а также умеренные длина описания и количество тегов,
97 свидетельствующие о четком позиционировании. Полученные выводы могут быть исполь-
98 зованы инвесторами и предпринимателями для оценки перспективности бизнес-проектов на
99 ранних стадиях.

100 Ключевые слова (TODO переделать)

101 Стартапы, предикторы успеха, разведочный анализ данных, визуализация данных,
102 статистический анализ, Y Combinator, корреляционный анализ, ошибка выжившего, когорт-
103 ный анализ

1 Основные термины и определения

- **Стартап** — это молодая, недавно созданная компания, находящаяся на стадии развития и строящая свой бизнес вокруг инновационной технологии, идеи или уникальной бизнес-модели. [23]
- **Предиктор успеха** — измеримый параметр или характеристика, статистически связанная с успехом или провалом стартапа.
- **Y Combinator** — один из крупнейших и наиболее известных стартап-акселераторов в мире, основанный в 2005 году. Среди выпускников — Airbnb, Dropbox, Stripe, Reddit и другие [22].
- **Батч** — набор компаний, получивших инвестиции в один период времени.
- **IPO** — первичное публичное размещение акций на фондовой бирже, в результате которого компания становится публичной [24].
- **Kaggle** — публичная веб-платформа, на которой пользователи и организации могут публиковать наборы данных, исследовать и создавать модели, взаимодействовать с другими специалистами по данным. [19]
- **Разведочный анализ данных (EDA)** — анализ основных свойств данных, нахождение в них общих закономерностей, распределений и аномалий, зачастую с использованием инструментов визуализации. [20]
- **Критерий Манна-Уитни** — непараметрический статистический тест для сравнения двух независимых выборок, не требующий предположения о нормальности распределения. [10]
- **Корреляция Пирсона** — мера линейной зависимости между двумя переменными, принимающая значения от -1 до $+1$. [11]
- **Ошибка выжившего** — систематическая ошибка отбора, при которой анализируются только «выжившие» объекты, а «не выжившие» игнорируются, что приводит к искаженным выводам.
- **Когортный анализ** — метод анализа, при котором объекты группируются по времени возникновения (когортам) и сравниваются внутри одной когорты, что позволяет контролировать временной фактор.

- **Crunchbase** — это онлайн-платформа, которая предоставляет информацию о стартапах, компаниях, инвесторах и предпринимателях по всему миру. [3]

2 Введение

2.1 Актуальность работы

Выбор компаний для инвестирования предполагает оценку их перспектив по сведениям, доступным до получения результата. Исследование Gompers и соавторов, основанное на опросе венчурных инвесторов, показывает, что при отборе компаний существенное значение придаётся характеристикам команды и бизнеса [4]. Это придаёт прикладной смысл исследованию предикторов успеха: важно установить, какие наблюдаемые характеристики действительно помогают прогнозировать последующие результаты, а не только учитываются участниками рынка при принятии решений. Сам по себе опрос предпочтений инвесторов на этот вопрос не отвечает.

Различие между признаками, которым придают значение, и признаками, полезными для прогноза, определяет аналитическую проблему работы. Как показывает Shmueli, объяснение наблюдаемых зависимостей и прогнозирование новых наблюдений являются разными задачами: убедительность объяснительной модели не гарантирует её предсказательного качества [18]. Поэтому содержательные предположения о роли команды, географии или направления деятельности нуждаются в самостоятельной прогностической проверке. Для исследования ключевых предикторов существенен не только факт связи признака с результатом, но и то, улучшает ли этот признак прогноз по сравнению с более простой моделью.

Открытые сведения позволяют поставить этот вопрос применительно к конкретному источнику данных. Каталог Y Combinator содержит карточки компаний со сведениями об их деятельности, командах и статусах [21]; на Kaggle опубликованы загрузки этого каталога [6, 5]. Доступность таких записей создаёт возможность эмпирической проверки, но сама по себе не подтверждает их пригодность для прогнозирования. С учётом разграничения описательного и прогностического анализа [18] в данной работе проверяется, какую дополнительную информацию о последующем статусе компаний дают характеристики их публичных карточек сверх сведений о годе набора YC.

Таким образом, работа связывает два вопроса: какие характеристики компаний рассматриваются при оценке их перспектив [4] и какие из доступных характеристик выдерживают проверку на прогностическую полезность [18]. Её предполагаемый вклад состоит в оценке

дополнительной информативности сведений о команде, географии и деятельности компаний YC, а также в наглядном представлении надёжности полученных различий. Такой результат позволит судить о возможностях конкретного источника данных для прогнозирования наблюдаемого показателя успеха, а не предлагать универсальный перечень условий успешного предпринимательства.

2.2 Цель

Целью работы является выявление и визуализация ключевых предикторов наблюдаемого показателя успеха компаний Y Combinator на основе оценки их вклада в качество прогноза последующего состояния.

Успех в рамках исследования определяется как наличие статуса поглощённой или публичной компании в срезе от 1 августа 2026 года у компании, активной на начало наблюдения. Такое объединение выделяет два наблюдаемых корпоративных события, однако служит лишь приближённым показателем успеха: данные о статусе не позволяют оценить доходность для владельцев, а поглощение не обязательно означает выгодную продажу. Поэтому наряду с объединённым показателем рассматривается состав положительного класса. Продолжение деятельности и неактивность означают отсутствие данного показателя в позднем срезе, но не трактуются как равнозначные экономические результаты.

Предикторами выступают характеристики, зафиксированные на начало периода наблюдения, а ключевыми считаются те из них, которые устойчиво улучшают прогноз на данных, не использованных при обучении и настройке модели. Исследование оценивает прогнозистические связи, а не причинные эффекты; его выводы характеризуют полезность доступных сведений для прогноза, а не способы обеспечить успех компании.

2.3 Объект исследования

Объектом исследования являются компании каталога YC, имевшие активный статус в выгрузке от 13 июля 2023 года. Единицей наблюдения служит компания с уникальным идентификатором. Её характеристики на эту дату сопоставляются со статусом в версии позднего датасета от 1 августа 2026 года; срез от 27 февраля 2023 года используется для проверки согласованности сведений. Анализируются сторонние выгрузки каталога, размещённые на Kaggle, а не данные, собранные автором непосредственно с сайта YC.

Состав исследуемой совокупности определяется по июльскому срезу. Компании, отсутствующие в поздней выгрузке, сохраняются в учёте как записи с неизвестным последующим

состоянием. Период сопоставления охватывает интервал с 13 июля 2023 года по 1 августа 2026 года, то есть немногим более трёх лет. Прогнозируется статус, зафиксированный в конечном срезе; точные даты переходов между состояниями по этим данным не определяются.

Выводы относятся к компаниям, активным на начало наблюдения. Измеренные характеристики отражают их состояние в июле 2023 года, а не обязательно на момент основания или поступления в акселератор. Поэтому результаты не переносятся автоматически на вновь созданные компании и предпринимательские инициативы вне УС.

2.4 Предмет исследования

Предметом исследования являются прогностические связи между характеристиками компаний на 13 июля 2023 года и их статусами на 1 августа 2026 года, а также вклад отдельных характеристик и их групп в качество прогноза наблюдаемого показателя успеха. Рассматриваются число основателей, размер команды, год основания, год и сезон набора УС, география, тематические теги и текстовые описания.

2.5 Методы исследования

2.5.1 Методы предобработки данных

Подготовка данных предусматривает проверку идентификаторов, устранение дубликатов, согласование форматов и сопоставление записей между срезами. Пропуски в признаках отделяются от неизвестных последующих состояний. Поздние значения не используются для восстановления характеристик на начало наблюдения; преобразования, параметры которых оцениваются по данным, настраиваются только на обучающей части выборки [9].

2.5.2 Разведочный анализ данных (EDA)

Разведочный анализ охватывает полноту данных, распределения характеристик, частоты статусов и связи между признаками. Отдельно сопоставляются компании разных годов набора и компании с известным и неизвестным последующим состоянием. Описательная статистика и графики служат для выявления особенностей выборки и ограничений дальнейшего моделирования.

2.5.3 Статистический анализ и прогнозное моделирование

Основной метод анализа — сравнение моделей бинарной классификации наблюдаемого показателя успеха. Предусматривается сопоставление простых прогнозов, включая модель по году набора, с регуляризованной логистической регрессией и градиентным бустингом. Вклад групп признаков оценивается по изменению качества при их добавлении и исключении на одинаковых проверочных разбиениях.

Оценка качества включает способность различать классы и точность прогнозируемых вероятностей. Настройка моделей отделяется от итоговой проверки; различия в качестве сопровождаются оценками неопределённости. Основные проверки устойчивости касаются состава признаков, обработки пропусков и неизвестных последующих состояний. Отсутствие устойчивого улучшения относительно простого прогноза также является содержательным результатом.

2.5.4 Анализ динамики

Сопоставление срезов используется для описания переходов от активного состояния к наблюдаемым позднее статусам. Продолжающие работать компании учитываются наряду с поглощёнными, публичными и неактивными. Даты изменения статуса не приравниваются к датам выгрузок; по двум наблюдениям не восстанавливается полная история компании.

2.5.5 Инструменты визуализации

Для визуализации предусмотрены библиотеки Python Matplotlib и Seaborn. Графики представляют состав выборки, переходы между статусами, сравнение моделей и вклад признаков с неопределённостью оценок. Подписи указывают анализируемую совокупность, единицы измерения и преобразования, необходимые для самостоятельного прочтения изображения.

2.6 Задачи

- 1 Рассмотреть исследования предикторов успеха стартапов и подходы к определению прогнозируемого результата.
- 2 Описать происхождение и временные ограничения данных, сформировать выборку для сопоставления характеристик и последующих статусов.

249 3 Провести разведочный анализ, оценить полноту признаков и особенности записей с
250 неизвестным последующим состоянием.

251 4 Сравнить простые и многомерные прогнозные модели, оценить дополнительную ин-
252 формативность сведений о команде, географии и деятельности компаний.

253 5 Проверить устойчивость различий в качестве и представить вклад признаков вместе с
254 неопределённостью оценок.

255 6 Визуализировать результаты и сформулировать выводы о возможностях прогнози-
256 рования по данным каталога и границах применимости этих выводов.

257 2.7 План работы

258 В таблице 2.1 приведён первоначальный календарный план с сохранением исходных
259 задач и сроков. Он отражает прежнюю постановку исследования: упоминания гипотез Н1–
260 Н8 и периода 2023–2025 годов относятся к первоначальному замыслу, а не к обновлённому
261 анализу.

262 Таблица 2.2 содержит план переработки с 12 августа 2026 года до защиты 3 октября
263 2026 года. Срок сдачи отчётных документов, включая текст курсовой работы, — 18 сентяб-
264 ря; презентация должна быть подготовлена и сдана до 1 октября включительно. Редактура
265 текста ведётся параллельно с анализом, чтобы завершить проверку результатов до сдачи
266 документов. План задаёт сроки задач, а не подтверждает их выполнение.

Таблица 2.1: Календарный план проекта (25.01.2026 – 01.04.2026)

Этап	Неделя / Период	Основные задачи	Результат
Этап 1: Подготовка данных и EDA	Неделя 1 25.01–31.01	Сбор данных (Kaggle); настройка окружения; слияние источников; обработка пропусков	Объединенные датасеты
–	Неделя 2 01.02–07.02	Создание производных признаков (бинарный статус, тип основателей); EDA: распределения, пропуски	Датасет А и В + ноутбук
–	Неделя 3 08.02–14.02	Анализ категориальных признаков; визуализация батчей, отраслей, стран	EDA-отчет с графиками
Этап 2: Анализ предикторов	Неделя 4 15.02–21.02	Проверка гипотез Н1–Н4: соло vs команда, B2B vs Consumer, сезон батча, лаконичность описания	Графики и статистические тесты
–	Неделя 5 22.02–28.02	Проверка гипотез Н5–Н8: количество тегов, найм, география, стадия развития	Полный набор визуализаций
–	Неделя 6 01.03–07.03	Корреляционный анализ; анализ динамики 2023–2025; матрица переходов	Корреляционная матрица + выводы
Этап 3: Оформление	Неделя 7 08.03–14.03	Написание отчета: введение, описание данных, методология	Черновик курсовой работы
–	Неделя 8 15.03–21.03	Написание отчета: результаты, выводы, оформление графиков	Полный текст работы
–	Финал 22.03–01.04	Проверка оформления; создание презентации; финализация	Готовый проект к защите

Таблица 2.2: План переработки и подготовки к защите (12.08.2026 – 03.10.2026)

Этап	Период	Основные задачи	Результат
1. Постановка исследования	12.08–18.08	Проверка литературы; уточнение показателя успеха, совокупности и периода наблюдения; редактura введения	Постановка и проверенные источники
2. Подготовка данных	19.08–25.08	Сопоставление компаний; разделение исходных признаков и поздних статусов; учёт пропусков и ненайденных записей	Аналитическая выборка и отчёт о преобразованиях
3. Обновление EDA	26.08–01.09	Пересчёт распределений и переходов; анализ пропусков и когорт; обновление графиков	Графики и раздел EDA
4. Прогнозные модели	02.09–08.09	Фиксация схемы проверки и метрик; сравнение простых прогнозов, логистической регрессии и градиентного бустинга	Сравнение моделей без утечки данных
5. Предикторы и устойчивость	09.09–14.09	Оценка вклада групп признаков, неопределённости и качества вероятностей; проверка чувствительности к пропускам	Оценки информативности и устойчивости
6. Переработка текста	12.08–16.09 Параллельно	Обновление обзора, методов и результатов; согласование чисел и графиков; исправление неподтверждённых выводов	Полный текст курсовой работы
7. Итоговая проверка	15.09–17.09	Повторный запуск анализа; проверка ссылок и сборки LaTeX; подготовка комплекта отчётных документов	Проверенный комплект документов
8. Сдача документов	18.09	Сдача отчётных документов, включая текст курсовой работы	Документы сданы
9. Презентация	19.09–01.10	Подготовка слайдов и доклада по сданной работе; проверка соответствия результатов; сдача презентации до 01.10 включительно	Презентация сдана
10. Подготовка к выступлению	02.10	Репетиция доклада; подготовка ответов на вопросы о методах и ограничениях	Готовность к выступлению
11. Защита	03.10	Доклад и ответы на вопросы комиссии	Защита курсовой работы

3 Обзор литературы

Исследования результатов молодых компаний различаются прежде всего определением результата и составом наблюдаемой совокупности. Привлечение следующего раунда финансирования, прекращение деятельности, поглощение и выход на биржу фиксируют разные события. Их нельзя объединять под названием «успех» без указания того, какое именно событие наблюдается и в течение какого периода [1, 17, 13].

3.1 Определение результата

Bruno, McQuarrie и Torgrimson [1] проследили судьбу 250 технологических компаний, основанных в Северной Калифорнии в 1960-е годы. К 1988 году 50% компаний прекратили деятельность, 32% были объединены с другими компаниями или поглощены, 18% продолжали самостоятельную работу. Такое разделение не сводит все исходы к противопоставлению «успеха» и «неудачи». Вместе с тем доли, полученные для компаний одного региона и периода, не характеризуют современные наборы Y Combinator (YC).

В исследовании CapitalVX на данных Crunchbase прогнозируются поглощение или выход компании на биржу, прекращение деятельности и сохранение частного статуса; последующее финансирование рассматривается отдельно [13]. Поглощение и публичный статус здесь представляют наблюдаемые корпоративные события, а не непосредственную оценку прибыльности компании или доходности инвестиций. В частности, поглощение может происходить на разных финансовых условиях, которые статус компании не раскрывает.

В исследуемых данных исходом считается наличие у компании, активной 13 июля 2023 года, статуса поглощённой или публичной на 1 августа 2026 года. Отсутствие такого статуса не означает прекращения деятельности: отрицательный класс включает также компании, которые продолжают работать. Записи без установленного статуса в позднем срезе составляют отдельную группу и не приравниваются к отрицательным наблюдениям. Это разграничение определяет смысл как описательных сравнений, так и прогнозных оценок.

3.2 Характеристики компаний и прогнозный анализ

Опрос 885 венчурных инвесторов из 681 организации, проведённый Gompers и соавторами [4], показал, что при принятии инвестиционных решений респонденты придают команде большее значение, чем продукту или технологии. Однако ответы инвесторов описывают критерии их выбора, а не точность прогноза по данным каталога YC. Доступные в

каталоге число основателей и размер команды не отражают опыт участников, распределение обязанностей и качество их взаимодействия. Поэтому результат опроса служит основанием включить сведения о команде в проверку, но не позволяет заранее ожидать от этих двух переменных улучшения прогноза.

Различие между объяснением наблюдаемой зависимости и прогнозированием новых наблюдений подробно рассмотрено Shmueli [18]. Для оценки прогностической полезности недостаточно содержательно истолковать связь признака с исходом: необходимо установить, повышает ли он качество на данных, не участвовавших в обучении. Это относится и к сведениям о географии и сфере деятельности компании. Их вклад определяется сравнением моделей на одинаковых проверочных наблюдениях, в том числе относительно простого прогноза по году набора УС.

3.3 Публичные сведения и текстовые признаки

Sharchilev и соавторы [17] прогнозировали получение раунда Series A или более позднего раунда в течение года после начального финансирования. Наряду со структурированными характеристиками они использовали сведения о сотрудниках и упоминания компаний в интернете. В таблице 4 статьи ROC-AUC полной модели равна 0,854; у варианта без подробных признаков доменов, упоминающих компанию, — 0,807. Различие получено для прогноза финансирования и определённого типа внешних сведений. Оно не устанавливает полезность описаний и тегов из карточек УС при прогнозировании поглощения или выхода на биржу.

Kaiser и Kuhn [7, 8] исследовали регистрационные сведения о 55 914 датских компаниях, основанных в 2012–2014 годах. Оценивались разные исходы, включая прекращение деятельности, рост занятости, высокую рентабельность активов и показатели инновационной активности. Текстовые описания деятельности помогали прогнозировать инновационные показатели, тогда как высокая рентабельность активов оставалась плохо предсказуемой [7]. Следовательно, информативность одного источника данных зависит от выбранного исхода. Обязательные регистрационные сведения, кроме того, отличаются от добровольно заполненных карточек УС охватом и правилами формирования.

В обоих исследованиях текстовые признаки оценивались в сравнении с другими наборами сведений. Даже при обнаружении прогностической связи описание компании может отражать её деятельность или другие свойства, связанные с исходом. Из такой связи не следует, что изменение формулировки описания изменит перспективы компании.

3.4 Время наблюдения и проверка качества

Sharchilev и соавторы [17] задают годовой горизонт прогноза и разделяют обучающие и проверочные наблюдения по времени. Kaiser и Kuhn, напротив, случайным образом отводят 70% компаний для оценки моделей и 30% для проверки; признаки, рассчитываемые с использованием исходов компаний, формируются на обучающей части [7]. Случайное разбиение позволяет оценить качество внутри изучаемой совокупности, но само по себе не проверяет прогноз на новом календарном периоде. Поэтому оценки из этих работ нельзя напрямую сопоставлять без учёта различий в исходах, горизонтах и схемах проверки.

Для компаний УС доступны характеристики на 13 июля 2023 года и статусы на 1 августа 2026 года. Два среза позволяют установить состояние на конечную дату, но не точный момент поглощения, выхода на биржу или прекращения деятельности. Разделение проверочных данных по наборам УС позволяет исследовать устойчивость различий между когортами; оно не воспроизводит проверку на последовательности будущих календарных периодов.

Кароог и Narayanan [9] описывают утечку информации как одну из причин завышенных оценок качества моделей. В рассматриваемой постановке исходные признаки должны относиться к июлю 2023 года, а параметры преобразований и моделей — оцениваться без использования проверочных наблюдений. Отдельное ограничение связано с компаниями, для которых статус на август 2026 года установить не удалось: их исключение из прогноза с известным исходом может изменить состав оцениваемой выборки. Ни учёт года набора, ни корректное разделение данных при обучении не устраняют это ограничение.

В отличие от работ о последующем финансировании, здесь оценивается конечный статус исходно активных компаний УС. Проверяется, улучшают ли характеристики, известные в июле 2023 года, прогноз поглощения или публичного статуса к августу 2026 года по сравнению с годом набора. Сопоставление моделей и групп признаков проводится с учётом неопределённости оценок и записей с неизвестным исходом. Даже устойчивое улучшение прогноза не свидетельствовало бы о причинном влиянии выявленных характеристик на судьбу компании [18].

4 Описание данных

4.1 Источники и даты наблюдения

Для исследования использованы три выгрузки каталога компаний Y Combinator с платформы Kaggle [6, 5]. Файлы за февраль и июль 2023 года имеют одинаковые поля. Поздняя выгрузка датирована 1 августа 2026 года. Состав файлов и их роль приведены в таблице 4.1. Дата выгрузки не означает, что каждое поле карточки было обновлено в этот день.

Таблица 4.1: Исходные файлы и их роль в исследовании. Число строк указано до удаления точных повторов, число компаний рассчитано по уникальным идентификаторам.

Дата выгрузки	Строк	Компаний	Полей	Использование
27.02.2023	4 128	4 128	16	Проверка согласованности с июльским файлом
13.07.2023	8 410	4 297	16	Определение исходной группы и её характеристик
01.08.2026	6 110	6 110	23	Определение последующего статуса

Февральскому срезу соответствует файл `2023-02-27-yc-companies.csv`, июльскому — `2023-07-13-yc-companies.csv`. Поздняя версия представлена файлом `yc_companies.csv`.

Сведения получены из сторонних выгрузок, а не собраны непосредственно с сайта Y Combinator. Контрольные суммы по алгоритму SHA-256 зафиксированы в отчёте о подготовке данных.

4.2 Поля исходных файлов

Структура файлов 2023 года приведена в таблице 4.2, структура позднего файла — в таблице 4.3. Для полей с многочисленными значениями указаны формат и примеры; конечные наборы статусов и логических значений перечислены полностью. Пустые ячейки означают отсутствие сведений в источнике. Там, где поздняя выгрузка не содержит словаря полей, их описание ограничено названием и форматом записанных значений.

Таблица 4.2: Поля февральской и июльской выгрузок 2023 года. Названия и примеры значений сохранены в форме исходных файлов.

Поле	Возможные значения	Содержание
company_id	Положительное целое число	Идентификатор компании в каталоге; служит ключом при сопоставлении выгрузок.
company_name	Текст, например moonrepo	Название компании; совпадение названий не заменяет совпадения идентификаторов.
short_description	Короткий текст либо пропуск	Однострочное описание деятельности компании.
long_description	Текст либо пропуск	Развёрнутое описание деятельности, если оно заполнено в карточке.
batch	Код набора, например W23, S22 или IK12	Обозначение набора Y Combinator. Буквы W и S обозначают зимний и летний наборы; IK12 не имеет стандартного сезонного обозначения.
status	Active, Inactive, Acquired, Public	Статус компании на дату соответствующей выгрузки.
tags	Список строк, например ['SaaS', 'B2B'], либо пустой список	Тематические метки карточки. Одна компания может иметь несколько меток.
location	Текст, например Portland, OR, либо пропуск	Местоположение в исходной записи без выделения страны и города по единому правилу.
country	Краткий код страны, например US или IN, либо пропуск	Страна, выделенная в источнике в отдельное поле.
year_founded	Год основания либо пропуск	Указанный в карточке год основания; точная дата не содержится в этом поле.
num_founders	Целое число от 0 до 6	Число основателей в источнике. Ноль при подготовке считается неизвестным значением.
founders_names	Список имён, в том числе пустой	Имена основателей в строковом представлении списка.
team_size	Неотрицательное целое число либо пропуск	Численность команды по карточке компании; ноль сохраняется как отдельное наблюдаемое значение.
website	Ссылка на сайт либо пропуск	Адрес сайта компании.
cb_url	Ссылка на Crunchbase либо пропуск	Адрес карточки компании в каталоге Crunchbase.
linkedin_url	Ссылка на LinkedIn либо пропуск	Адрес страницы компании в LinkedIn.

В поздней выгрузке отсутствуют отдельные поля страны, года основания, числа и имён основателей. Эти сведения не восстанавливались по поздним адресам или другим полям: признаки для анализа исходного состояния взяты из июльского файла.

376 Одноимённые по смыслу поля приведены к общей схеме: `company_id` раннего файла
377 и `id` позднего получили название `id`. Поля `launched_at`, `industries`, `regions`, `app_video_`
378 `public`, `demo_day_video_public`, `app_answers` и `question_answers` не вошли в очищенный
379 поздний срез. Из него к исходным записям присоединён только статус; остальные поздние
380 характеристики не использованы как признаки прогноза.

Таблица 4.3: Все поля выгрузки от 1 августа 2026 года. Для перечислений с множеством значений приведены формат и примеры.

Поле	Возможные значения	Содержание
<code>id</code>	Положительное целое число	Идентификатор компании; сопоставляется с полем <code>company_id</code> ранней выгрузки.
<code>name</code>	Текст	Название компании в позднем каталоге.
<code>website</code>	Ссылка на сайт либо пропуск	Адрес сайта компании на дату поздней выгрузки.
<code>all_locations</code>	Перечень мест текстом либо пропуск	Все местоположения, указанные в карточке; несколько мест могут быть разделены точкой с запятой.
<code>long_description</code>	Текст либо пропуск	Развёрнутое описание компании в поздней карточке.
<code>one_liner</code>	Короткий текст либо пропуск	Однострочное описание компании; по смыслу соответствует раннему <code>short_description</code> .
<code>team_size</code>	Неотрицательное целое число либо пропуск	Численность команды в поздней карточке. Для исходных признаков это значение не используется.
<code>industry</code>	Девять категорий: B2B, Consumer, Education, Fintech, Government, Healthcare, Industrials, Real Estate and Construction, Unspecified	Широкая категория деятельности в классификации позднего источника.
<code>subindustry</code>	Категория, например B2B -> Infrastructure	Более подробное направление деятельности; в файле встречаются 59 обозначений.
<code>launched_at</code>	Дата и время, например 2011-11-23 10:52:03	Метка времени запуска, указанная источником. Она не приравнивается к году основания компании.
<code>tags</code>	Список строк либо пустой список	Тематические метки в поздней карточке. Они могут отличаться от меток 2023 года.
<code>top_company</code>	True, False либо пропуск	Отметка компании как одной из выделенных в каталоге.
<code>isHiring</code>	True или False	Признак открытого найма в поздней карточке.
<code>nonprofit</code>	True или False	Признак некоммерческой организации.
<code>batch</code>	Сезон и год, например Winter 2022; также Unspecified	Обозначение набора Y Combinator в формате позднего источника. В файле есть весенние и осенние наборы, а также одна запись с годом 2027.
<code>status</code>	Active, Inactive, Acquired, Public	Статус компании на дату поздней выгрузки; единственное содержательное поле, переносимое в исследуемую группу.
<code>industries</code>	Список строк, например ['B2B', 'Infrastructure']	Перечень уровней отраслевой классификации в исходной карточке.

Продолжение таблицы 4.3

Поле	Возможные значения	Содержание
<code>regions</code>	Список строк, например <code>['Europe', 'Remote']</code>	Географические и связанные с удалённой работой метки источника; это не отдельное поле страны.
<code>stage</code>	<code>Early</code> или <code>Growth</code>	Категория стадии развития в позднем каталоге.
<code>app_video_public</code>	<code>True</code> или <code>False</code>	Признак публичной доступности видеозаписи из заявки в Y Combinator.
<code>demo_day_video_public</code>	<code>True</code> или <code>False</code>	Признак публичной доступности видеозаписи выступления на презентационном дне.
<code>app_answers</code>	<code>True</code> , <code>False</code> либо пропуск	Признак, связанный с ответами из заявки. В 6 033 из 6 110 строк значение отсутствует; смысл пропуска источник не разъясняет.
<code>question_answers</code>	<code>True</code> или <code>False</code>	Признак публичной доступности ответов компании на вопросы в каталоге.

4.3 Формирование исследуемой группы и производные поля

Единица наблюдения — компания с уникальным идентификатором. Исходная группа состоит из 3 110 компаний со статусом `Active` в июльской выгрузке. Февральский файл использован для проверки согласованности записей, но не для заполнения июльских пропусков. Производные поля рассчитаны после удаления повторов и очистки исходных значений.

В таблице 4.4 перечислены производные характеристики, технические поля и целевая переменная. Технические поля предназначены для учёта происхождения записей и сопоставления срезов; в прогноз они не включены.

Таблица 4.4: Производные и технические поля подготовленных данных. Расчёт характеристик компании выполняется отдельно внутри каждого среза; в прогноз поступают только характеристики июля 2023 года.

Поле	Возможные значения	Способ получения
<code>tags</code>	Список различных меток; возможен пустой список	Строковое представление разбирается в список; пробелы по краям меток удаляются, повторы исключаются.
<code>tag_count</code>	Неотрицательное целое число	Число различных меток после разбора <code>tags</code> ; пустому списку соответствует ноль.
<code>description_length</code>	Неотрицательное целое число либо пропуск	Число символов в очищенном кратком описании. При отсутствии описания длина остаётся неизвестной.
<code>company_age</code>	Неотрицательное число лет либо пропуск	Год среза минус <code>year_founded</code> . Это разность календарных лет, а не возраст в полных годах.
<code>batch_year</code>	Год набора либо пропуск	Год выделяется из <code>batch</code> . Если он позже года среза, числовое значение признаётся недопустимым.
<code>batch_season</code>	<code>Winter</code> , <code>Summer</code> , <code>Spring</code> , <code>Fall</code> либо пропуск	Сезон выделяется из стандартного кода набора. Для IK12 сезон не назначается.

Продолжение таблицы 4.4

Поле	Возможные значения	Способ получения
<code>regular_batch</code>	True или False	Показывает, распознан ли обычный код с сезоном и годом. Для IK12 и нераспознанных обозначений значение ложно.
<code>future_batch</code>	True или False	Показывает, что извлечённый год набора позже года соответствующего среза. Исходный код при этом сохраняется, а <code>batch_year</code> становится пропуском.
<code>snapshot_date</code>	Дата соответствующей выгрузки	Постоянная дата, присвоенная всем строкам очищенного среза.
<code>source</code>	yc_2023_feb, yc_2023_jul или yc_2026	Обозначение файла-источника, присвоенное при загрузке.
<code>status_baseline</code>	active	Июльский статус после отбора исходной группы; исходное поле <code>status</code> переименовано.
<code>status_followup</code>	active, inactive, acquired, public, unknown	Статус сопоставленной компании из позднего файла. При отсутствии записи проставляется <code>unknown</code> .
<code>followup_found</code>	True или False	Результат сопоставления идентификатора с поздним файлом.
<code>outcome_known</code>	True или False	Показывает, входит ли поздний статус в четыре распознаваемые категории.
<code>success_binary</code>	1, 0 либо пропуск	Единица присваивается статусам <code>acquired</code> и <code>public</code> ; ноль — статусам <code>active</code> и <code>inactive</code> . При неизвестном статусе значение отсутствует.
<code>followup_date</code>	2026-08-01	Постоянная дата поздней выгрузки, записанная после сопоставления.

При очистке пустые строки заменены пропусками, статусы приведены к строчным буквам. Коды стран записаны заглавными буквами: USA и UNITED STATES заменены на US, UK и UNITED KINGDOM — на GB. Нулевое число основателей переведено в пропуск, нулевой размер команды сохранён. Отрицательные и дробные значения размера команды, числа основателей и года основания признаны недопустимыми. Год основания также переведён в пропуск, если он равен нулю или превышает год выгрузки.

В прогнозном эксперименте размер команды представлен как $\ln(1 + x)$, где x обозначает число человек. Неизвестный сезон выделен в отдельную категорию. При обучении логистической регрессии пропуски числовых признаков отмечены отдельными индикаторами, а год набора и возраст представлены сплайнами. Заполнение числовых пропусков и оценка параметров преобразования проводились только на обучающих частях. Подробности приведены в разделе 6.

4.4 Последующий статус и границы наблюдения

Исходные и поздние записи сопоставлены по уникальному идентификатору с сохранением всех компаний июльской группы. У 3 046 компаний поздний статус установлен; 64 компании в файле от 1 августа 2026 года не найдены и сохранены с неизвестным исходом. Компании, присутствующие только в поздней выгрузке, в исследуемую группу не вошли.

Положительная метка присвоена поглощённым и публичным компаниям, отрицательная — активным и неактивным на 1 августа 2026 года. При неизвестном позднем статусе метка отсутствует. Отрицательный класс означает лишь отсутствие выбранного корпоративного события на конечную дату; финансовый результат компании и дата события по этим данным не определяются.

4.5 Проверки и воспроизводимость

Удалены только полностью совпадающие строки. Отсутствующий либо некорректный идентификатор и несовпадающие записи с одним идентификатором считались ошибками, препятствующими сопоставлению; в использованных файлах таких конфликтов после удаления повторов не обнаружено. Коду IK12 сезон не присвоен. При разборе полных обозначений наборов **Spring** отделён от **Summer**.

Сохранены очищенные срезы, исследуемая группа и машиночитаемый отчёт о подготовке. Отчёт фиксирует размеры и контрольные суммы файлов, пропуски, удалённые повторы, недопустимые числовые значения и результаты сопоставления. Для разведочного анализа использована сохранённая группа компаний; сводные таблицы, лежащие в основе рисунков, также записаны в отдельные файлы.

5 Разведочный анализ данных

Разведочный анализ выполнен для компаний Y Combinator, имевших активный статус 13 июля 2023 года. Исходные характеристики взяты из выгрузки на эту дату, последующие статусы — из выгрузки от 1 августа 2026 года. Рассмотрены состав исследуемой группы, полнота записей и распределения характеристик. Источники данных опубликованы на Kaggle [6, 5].

5.1 Формирование исследуемой совокупности

В июльском файле из 8 410 строк 4 113 являются точными повторами. После их удаления остаются 4 297 компаний с уникальными идентификаторами. На исходную дату 3 110 из них были активны и вошли в исследуемую группу. Среди остальных 665 компаний были неактивны, 506 поглощены и 16 имели публичный статус. В поздней выгрузке найдены 3 046 компаний исходной группы; 64 записи отсутствуют. Последним не присвоена отрицательная целевая метка, поскольку их статус на 1 августа 2026 года не установлен.

С февральской выгрузкой совпадают 4 113 июльских идентификаторов. Только в феврале представлены 15 компаний, только в июле — 184. Среди общих записей изменились 68 статусов, 357 значений размера команды и 62 года основания. В подсчёте учтены также переходы между заполненным и пустым значением. По двум выгрузкам нельзя отделить изменение характеристики от исправления карточки. Февральские значения не использованы для заполнения июльских пропусков.

Исходная группа ограничена компаниями, представленными в каталоге и сохранившими активный статус к июлю 2023 года. Поэтому её характеристики не описывают все компании, когда-либо принятые в Y Combinator, и тем более все предпринимательские инициативы.


5.2 Полнота исходных характеристик

На рисунке 5.1 приведены пропуски исходных характеристик. Год основания не указан у 356 компаний, что составляет 11,45% исследуемой группы. Подробное описание отсутствует у 206 компаний, страна — у 89, размер команды — у 47, краткое описание — у 43. Число основателей неизвестно у четырёх компаний после замены исходных нулей на пропуски.

Пустой список тегов имеют 145 компаний, или 4,66% группы. Для них число перечисленных меток равно нулю; сведения о деятельности компании могут при этом содержаться

Полнота исходных характеристик компаний

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Сведения на 13.07.2023. Пустой список тегов означает отсутствие перечисленных тегов. Нулевое число основателей признано неизвестным; поздними значениями пропуски не заполнены.
Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.1: Пропуски характеристик среди 3 110 компаний Y Combinator, активных 13 июля 2023 года. Столбцы показывают число компаний без указанных сведений, подписи — долю исходной группы. Пустые списки тегов учтены отдельно; данные от 1 августа 2026 года для заполнения пропусков не использованы.

в описании. Длина описания и количество тегов характеризуют заполнение карточки, а не качество продукта.

Размер команды, число основателей, возраст, страна и краткое описание одновременно известны у 2 632 компаний. Полное исключение строк с пропусками в этих пяти полях сократило бы исходную группу на 478 компаний, или 15,37%. В описательных расчётах пропуски исключались отдельно для каждого показателя; в прогнозном анализе заполнение числовых значений выполнялось внутри обучающих частей.


5.3 Последующие статусы и наблюдаемый показатель успеха

На 1 августа 2026 года активный статус сохранили 2 405 компаний исходной группы; 369 были неактивны, 265 поглощены, семь имели публичный статус. Распределение приведено на рисунке 5.2. Для 64 компаний поздний статус неизвестен. Зафиксированные статусы не содержат даты перехода между состояниями.

Положительная целевая метка присвоена 272 компаниям, или 8,93% от 3 046 компаний с известным статусом. Остальные 2 774 компании образуют отрицательный класс: на конечную дату они были активны либо неактивны, но не поглощены и не публичны. Эта метка не

Статусы компаний к концу периода наблюдения

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Показатель успеха: поглощение или публичный статус. Активные компании не исключены. Неизвестный статус не приравнивается к неактивности; статус каталога не задаёт точную дату события.
Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.2: Статусы на 1 августа 2026 года у 3 110 компаний Y Combinator, активных 13 июля 2023 года. Количество и доля каждой группы рассчитаны с учётом 64 компаний без известного позднего статуса. Положительная целевая метка объединяет поглощённые и публичные компании.

является общей оценкой экономического результата компании.

На поглощения приходятся 265 из 272 положительных исходов, или 97,43%. Поэтому качество прогноза объединённого показателя в основном отражает распознавание поглощённых компаний. Семь публичных компаний представлены слишком малой группой для самостоятельной оценки качества прогноза этого исхода.

При двух крайних вариантах статуса 64 ненайденных компаний доля положительного исхода среди всех 3 110 исходных компаний находится между $272/3\,110 = 8,75\%$ и $336/3\,110 = 10,80\%$. Эти границы отражают только неизвестные исходы и не учитывают возможные ошибки в записанных статусах.


5.4 Годы набора и доступность последующих статусов

Компании сгруппированы по году поступления в Y Combinator. На рисунке 5.3 поставлены численность групп и распределение поздних статусов внутри них. Ранние годы объединены, нестандартный код IK12 выделен отдельно.

К наборам 2021–2023 годов относятся 1 680 компаний, или 54,02% исходной группы. На 2018–2020 годы приходятся 845 компаний, на 2015–2017 годы — 357, на стандартные наборы

Годы набора и последующие статусы исходной когорты

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Группы заданы по году набора; малочисленные ранние годы объединены. IK12 показан отдельно от стандартных сезонных наборов. На правой панели знаменатель — все компании группы, включая неизвестные статусы.

Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.3: Численность и поздние статусы компаний Y Combinator по годам набора. Показаны 3 110 компаний, активных 13 июля 2023 года; статусы относятся к 1 августа 2026 года. Слева указано число компаний, справа — доли статусов внутри каждой группы, в том числе неизвестных. Ранние годы объединены; IK12 оставлен отдельной группой.

2006–2014 годов — 184. Ещё 44 компании имеют код IK12. Распределение отражает состав действующих компаний на июль 2023 года, а не число всех когда-либо принятых компаний: более ранние участники, утратившие активный статус до этой даты, отсутствуют.

Поздняя выгрузка не содержит 43 из 44 компаний группы IK12; доля найденных записей в ней составляет 97,73%. Эта группа даёт 67,19% всех неизвестных исходов. Среди остальных 3 066 компаний не найдена 21, или 0,68%. Следовательно, общая доля сопоставления 97,94% скрывает сильную неоднородность по обозначению набора. Причина почти полного отсутствия IK12 в позднем источнике по имеющимся данным не установлена.

У компаний с неизвестным поздним статусом чаще отсутствует год основания: 31 из 64 записей, или 48,44%. Среди компаний с известным статусом этот показатель равен 325 из 3 046, или 10,67%. Поэтому выборка с известным исходом отличается от полной исходной группы не только доступностью целевой метки, но и полнотой характеристик.


Интервал между двумя срезами одинаков для всех компаний, но группы по году набора различаются возрастом и временем, прошедшим после поступления в акселератор. Наблюдаемые различия статусов не отделяют влияние года набора от этих характеристик.

5.5 Распределения числовых характеристик

На рисунке 5.4 представлены размер команды, число основателей и приближённый возраст на июль 2023 года. Возраст рассчитан как разность календарных лет между исходным срезом и основанием компании.

Размер команды, число основателей и возраст компаний

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Все признаки измерены на 13.07.2023, пропуски исключены отдельно для каждой панели. Размер команды: высота столбца — число компаний в интервале, не плотность; показаны все значения, включая нули.
Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.4: Распределения характеристик компаний Y Combinator, активных 13 июля 2023 года. Размер команды известен у 3 063 компаний, число основателей — у 3 106, приближённый возраст — у 2 754. По вертикали показано число компаний. Для размера команды применена шкала $\ln(1 + x)$ с подписями в количестве человек; столбцы показывают число компаний в интервалах, а не плотность.

Медианный размер команды составляет девять человек, первый и третий квартили — три и 25 человек. Среднее равно 55,59, максимум — 7 000. У 90% компаний с заполненным полем команда насчитывает не более 80 человек. Из-за редких больших значений среднее заметно превышает медиану. Логарифмическая шкала позволяет показать небольшие команды без удаления 11 нулевых наблюдений и крайних значений; достоверность отдельных крупных значений по одному распределению не установлена.

Два основателя указаны у 1 725 компаний, или 55,54% записей с известным числом основателей. Один основатель указан у 692 компаний, три — у 575. От четырёх до шести основателей имеют в сумме 114 компаний.


Медианный приближённый возраст равен трём календарным годам, первый и третий квартили — двум и пяти годам; наблюдаемый диапазон составляет от нуля до 18 лет. Это возраст компаний, остававшихся активными на июль 2023 года, а не распределение срока существования всех компаний акселератора.

5.6 Исходный размер команды в группах последующего статуса

На рисунке 5.5 исходный размер команды сопоставлен с поздним статусом компании. Скрипичные диаграммы показывают распределение значений на логарифмической шкале; коробки и усы рассчитаны по исходному числу сотрудников. Чтобы редкие очень крупные команды не растягивали оценку плотности, значения выше 99-го перцентиля в каждой группе показаны точками отдельно. При оценке квартилей эти значения сохранены.

Исходный размер команды и последующий статус компании

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Группы заданы статусом на 01.08.2026. Скрипки: плотность на логарифмической шкале без значений выше 99-го перцентиля каждой группы; ширина нормирована отдельно. Эти значения показаны точками. Коробки и усы рассчитаны по всем данным до преобразования шкалы. Семь публичных компаний показаны точками без оценки плотности. Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.5: Размер команды на 13 июля 2023 года по статусу компании на 1 августа 2026 года. Рассмотрены компании Y Combinator, активные на исходную дату; у каждой группы указано число записей с известным размером команды. Ширина скрипки показывает плотность на шкале $\ln(1 + x)$ и нормирована отдельно для каждой группы. Значения выше 99-го перцентиля исключены только из оценки плотности и показаны точками. Коробки и усы рассчитаны по всем исходным значениям: черта показывает медиану, коробка — межквартильный интервал, усы — крайние значения в пределах полутора межквартильных размахов. Семь публичных компаний показаны точками без оценки плотности. Подписи горизонтальной оси даны в количестве человек.

У компаний, сохранивших активный статус, медианный исходный размер команды равен десяти человек; у ставших неактивными — пяти, у поглощённых — восьми. Межквартильные интервалы составляют соответственно 4–30, 2–10 и 4–22,5 человека. Скрипичные диаграммы показывают концентрацию небольших команд во всех трёх группах и существенное перекрытие распределений. Поглощённые компании не выделяются более крупными исходными командами по сравнению с продолжающими работать.

В группе ставших неактивными у 76,0% компаний с известным размером команды было не более десяти сотрудников. Среди сохранивших активный статус эта доля составляет 52,7%, среди поглощённых — 58,9%. Обратная картина наблюдается в правой части распределения: команды численностью свыше 50 человек имели 3,9% ставших неактивными компаний, 16,4% сохранивших активный статус и 13,3% поглощённых. Таким образом, различия касаются не только медианы, но и доли крупных команд; сами по себе они не устанавливают влияния размера команды на последующий статус.

У семи компаний с последующим публичным статусом медианный размер команды на исходную дату равен 1 050 человек, межквартильный интервал — 175–2 425. Эта малочисленная группа отличается по масштабу от остальных и делает положительный класс неоднородным. Различия на рисунке не учитывают возраст и направление деятельности компаний.

5.7 Связи между числовыми признаками

Матрица на рисунке 5.6 содержит ранговые корреляции Спирмена между пятью исходными характеристиками. Коэффициент отражает согласованность порядка значений, а не линейное изменение одного признака при изменении другого. Каждая оценка рассчитана по компаниям с двумя известными значениями; число таких компаний указано в клетке.

Наибольшая по модулю корреляция наблюдается между возрастом и размером команды: $\rho_S = 0,58$ по 2 716 компаниям. Более старшим компаниям чаще соответствует большая численность команды. Признаки связаны, но не взаимозаменяемы; сравнение команд между группами позднего статуса без учёта возраста может смешивать эти различия.

Корреляция возраста с числом тегов равна $\rho_S = -0,33$, размера команды с числом основателей — $\rho_S = 0,12$. Отрицательная связь возраста с числом тегов может отражать различия в заполнении карточек компаний разных лет; установить её причину по матрице нельзя.

Оценки рассчитаны на разных подмножествах компаний из-за пропусков. Матрица характеризует парные монотонные связи между признаками; она не показывает их дополнительный вклад в прогноз позднего статуса.

5.8 Географический состав

Географический состав исходной группы представлен на рисунке 5.7. Для сравнения США со странами, имеющими несколько десятков наблюдений, использована логарифмическая шкала числа компаний.

Ранговые связи между исходными числовыми признаками

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.


Размер команды	+1,00 n=3063	+0,12 n=3059	+0,58 n=2716	-0,14 n=3063	+0,15 n=3022
Число основателей	+0,12 n=3059	+1,00 n=3106	-0,07 n=2752	+0,08 n=3106	-0,02 n=3064
Возраст компании	+0,58 n=2716	-0,07 n=2752	+1,00 n=2754	-0,33 n=2754	+0,19 n=2742
Число тегов	-0,14 n=3063	+0,08 n=3106	-0,33 n=2754	+1,00 n=3110	-0,07 n=3067
Длина краткого описания	+0,15 n=3022	-0,02 n=3064	+0,19 n=2742	-0,07 n=3067	+1,00 n=3067
	Размер команды	Число основателей	Возраст компании	Число тегов	Длина краткого описания

Коэффициент Спирмена, расчёт по попарно полным наблюдениям; n — число пар. Насыщенность синего показывает модуль, знак указан числом. Возраст = 2023 — год основания; длина описания — число символов. Целевая переменная не включена. Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.6: Ранговые корреляции Спирмена между характеристиками 3 110 компаний Y Combinator, активных 13 июля 2023 года. В каждой клетке указаны коэффициент и число компаний с обоими известными значениями. Насыщенность цвета соответствует модулю коэффициента, направление связи показывает его знак. Возраст рассчитан по разности календарных лет, длина описания измерена в символах; поздний статус в матрицу не включён.

Десять наиболее представленных стран исходной когорты

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Страна из исходного среза, без восстановления по поздним сведениям. Проценты от всех 3 110 компаний. Страна не указана у 89; остальные страны вне первой десятки не показаны.
Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.7: Десять наиболее представленных стран среди 3 110 компаний Y Combinator, активных 13 июля 2023 года. Положение точки показывает число компаний на логарифмической шкале, подпись — количество и долю всей исходной группы. Страна взята из июльской выгрузки; у 89 компаний она отсутствует. Остальные страны на рисунке не показаны.

США указаны у 2 024 компаний, или 65,08% исходной группы. Индия представлена 181 компанией, Канада — 112, Великобритания — 105. У следующих шести стран на рисунке от 34 до 78 компаний. За пределами первой десятки находятся ещё 325 компаний; у 89 страна неизвестна. Доли рассчитаны по всем 3 110 исходным компаниям, а не только по показанным странам.

На США приходится около двух третей исходной группы. Для большинства других стран число компаний невелико, а число положительных исходов ещё меньше. Показанное распределение характеризует присутствие стран в выборке, но не частоту поглощений или публичных статусов внутри них.


5.9 Тематические теги исходных карточек

На рисунке 5.8 показаны метки, перечисленные в июльских карточках компаний. Отраслевая классификация поздней выгрузки в исходные признаки не включена. Одна компания учитывается не более одного раза для каждого тега, но может присутствовать в нескольких строках рисунка.

Чаще всего встречается метка SaaS, обозначающая программное обеспечение как услу-

Пятнадцать наиболее частых тегов деятельности компаний

YC: 3 110 компаний, активных 13.07.2023. Последующие статусы: 01.08.2026.



Теги на 13.07.2023: одна компания может иметь несколько тегов; сумма долей не обязана равняться 100%. Пустые списки: 145. AI и Artificial Intelligence сохранены как разные исходные теги; это не классификация отраслей.
 Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рис. 5.8: Пятнадцать наиболее частых меток у 3110 компаний Y Combinator, активных 13 июля 2023 года. Показаны число компаний с каждой меткой и доля всей исходной группы. Одна компания может иметь несколько меток, поэтому доли не суммируются до 100%. Обозначения AI и Artificial Intelligence сохранены раздельно; у 145 компаний список меток пуст.

572 гу: её имеют 819 компаний, или 26,33% группы. Метка B2B для решений, адресованных ор-
573 ганизациям, указана у 710 компаний, метка **Fintech** для финансовых технологий — у 559,
574 инструменты для разработчиков — у 338. Эти обозначения описывают разные стороны дея-
575 тельности и не образуют взаимоисключающую отраслевую классификацию.

576 Несколько меток относятся к искусственному интеллекту: *Artificial Intelligence* встре-
577 чается у 269 компаний, AI — у 130, *Generative AI* — у 114; метка машинного обучения ука-
578 зана у 173 компаний. Эти группы могут пересекаться, поэтому сумма чисел не показывает
579 количество компаний, работающих с искусственным интеллектом. Исходные обозначения на
580 рисунке не объединены.

581 В первом прогнозном эксперименте тематические метки не использовались; их объ-
582 единение в смысловые группы не выполнялось.

6 Методология прогнозного анализа

6.1 Задача и границы первого эксперимента

Прогнозный анализ проверяет, улучшают ли характеристики команды предсказание последующего статуса компании сверх сведений о наборе УС и возрасте. Рассматриваются 3 046 компаний, активных 13 июля 2023 года и имеющих известный статус на 1 августа 2026 года. Положительная метка соответствует поглощению или публичному статусу (272 компании), отрицательная — активности или неактивности (2 774 компании). Остальные 64 компании исходной когорты не получают искусственных меток и не участвуют в обучении либо расчёте качества.

Прогнозируется условная вероятность выбранного положительного статуса по исходным характеристикам. Оценка качества непосредственно относится к компаниям с известным исходом. Концентрация неизвестных состояний в группе IK12, установленная в EDA, ограничивает перенос результатов на всю исходную когорту. Отбор по наличию наблюдаемого исхода не устраняется перекрёстной проверкой.

Первый эксперимент ограничен годом и сезоном набора, приближённым возрастом, размером команды и числом основателей. География, тематические теги и тексты оставлены для отдельного расширения. Такое ограничение позволяет проверить полезность сведений о команде при одинаковом составе остальных признаков. Протокол, сетки параметров и случайные начальные значения сохранены до запуска обучения; это фиксация вычислительной процедуры после разведочного анализа, а не предварительная регистрация всего исследования.

6.2 Сравнимые модели и обработка признаков

Отправной точкой служит постоянный прогноз: каждой проверяемой компании назначается доля положительных исходов в соответствующей обучающей части. С ним сравниваются три варианта регуляризованной логистической регрессии: по набору; по набору и возрасту; по набору, возрасту и двум характеристикам команды. Для краткости в таблицах и рисунках логистическая регрессия обозначается ЛР.

Логистическая регрессия задаёт вероятность как

$$\hat{p}(x) = \frac{1}{1 + \exp\{-\eta(x)\}}, \quad \eta(x) = \beta_0 + \beta^\top z(x),$$

где $z(x)$ — преобразованные признаки. Для года набора и возраста используются кубические сплайны с четырьмя равномерно расположенными узлами в диапазоне обучающих значений. Это допускает нелинейную зависимость, не отдавая бустингу преимущество только из-за заведомо линейной базовой модели. За пределами обучающего диапазона сплайн продолжается постоянным значением; отдельная оценка экстраполяции на будущие годы не проводится.

Размер команды заменяется на $\ln(1+x)$ с сохранением нулей. Число основателей включается как числовой признак. Пропуски числовых значений заполняются медианами обучающей части; дополнительно включаются индикаторы их отсутствия. Числовые представления масштабируются по обучающим данным. Сезон кодируется отдельными бинарными столбцами, отсутствие сезона — отдельной категорией. Используется квадратичная регуляризация с выбором параметра $C \in \{0, 1; 1; 10\}$, обратного силе штрафа. Индикаторы пропусков не масштабируются.

Второе семейство — CatBoost, реализация градиентного бустинга над деревьями с поддержкой категориальных признаков [12]. Сравниваются четыре варианта: набор и возраст; те же признаки с двумя характеристиками команды; исключение размера команды; исключение числа основателей. Сезон передаётся как категориальный признак. Числовые пропуски обрабатываются встроенным механизмом CatBoost, без предварительного заполнения медианами. Преобразование размера команды совпадает с используемым в логистической регрессии.

Для CatBoost перебираются глубины деревьев 3 и 5 и число итераций 200 и 500, всего четыре комбинации. Скорость обучения равна 0,03, коэффициент регуляризации листьев — 5. Число итераций выбирается во внутренней проверке; внешняя часть не используется для ранней остановки. Это ограниченное сравнение заранее заданных конфигураций, а не поиск наилучшего возможного варианта CatBoost.

Ни одна модель не использует идентификатор компании, поздние характеристики или поздний статус в качестве признака. Взвешивание классов и искусственное выравнивание их численности не применяются: основной объект оценки — вероятность исхода при наблюдаемой частоте классов. Изменение весов потребовало бы отдельно учитывать его влияние на вероятностные прогнозы.

6.3 Вложенная перекрёстная проверка

Настройка параметров отделяется от оценки качества вложенной перекрёстной проверкой [15]. Во внешнем цикле данные делятся на пять частей. Каждая часть по очереди

используется только для проверки, остальные четыре — для обучения и настройки. Внутри внешней обучающей части выполняется трёхчастная проверка. Для каждой конфигурации суммируются потери на внутренних проверочных наблюдениях и делятся на их общее число. Выбирается конфигурация с наименьшей потерей, затем модель заново обучается на всей внешней обучающей части.

Все оцениваемые по данным преобразования логистической регрессии входят в единую последовательность обучения. Их параметры заново определяются в каждой внутренней и внешней обучающей части, без использования проверочных значений. Таким образом, настройка включает и представление признаков, и модель, что необходимо для предотвращения утечки информации [9].

Основная схема стратифицирована по целевой переменной и повторяется дважды с начальными значениями генератора 42 и 137. В каждом повторе компания получает ровно один внешний проверочный прогноз от модели, не обучавшейся на ней. Метрики сначала рассчитываются по всем проверочным прогнозам одного повтора, затем усредняются между повторами. Усреднение вероятностей двух повторов перед расчётом основной метрики не производится. Все восемь вариантов используют одинаковые внешние и внутренние разбиения.

Дополнительная схема сохраняет компании одного набора УС в одной части. Группа определяется полным исходным кодом набора, а не только годом. Такое разделение применяется и во внешнем, и во внутреннем циклах с попыткой сохранить соотношение классов. Выполняется один повтор с пятью внешними и тремя внутренними частями. Для каждого разбиения проверяются отсутствие общих групп и наличие обоих классов в обучении и проверке.

Вторая схема характеризует переносимость между наборами компаний. Она не воспроизводит прогнозирование из прошлого в новый календарный период: признаки всех компаний относятся к июлю 2023 года, исходы — к августу 2026 года. Обе оценки являются внутренней ретроспективной проверкой. Поскольку вся когорта уже рассматривалась в EDA, эти результаты также не представляют независимого подтверждения гипотез, возникших после просмотра данных.

6.4 Метрики и дополнительная полезность признаков

Основной критерий настройки и сравнения — средняя логарифмическая потеря:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)] .$$

Меньшее значение соответствует лучшему вероятностному прогнозу по этому критерию. Дополнительно рассчитываются средняя точность ранжирования положительного класса (Average Precision, AP), площадь под ROC-кривой (ROC-AUC) и ошибка Брайера $n^{-1} \sum_i (y_i - \hat{p}_i)^2$. Первые две метрики оценивают ранжирование, последняя — квадратичную ошибку вероятностей. AP вычисляется как сумма точности, взвешенной приращениями полноты, а не как трапецидальная площадь под кривой точности и полноты [14].

Общая доля верных классов не используется для выбора модели: постоянное предсказание отрицательного класса уже даёт 91,07%. Порог классификации не подбирается, поскольку в задаче не заданы стоимости решений. Калибровка описывается отдельным графиком средних вероятностей и наблюдаемых частот в пяти приблизительно равных по численности группах. Этот график служит диагностикой; дополнительное преобразование вероятностей по нему не обучается.

Для оценки вклада признаков используются парные сравнения моделей на одних и тех же компаниях. Добавление команды сравнивается с моделью по набору и возрасту отдельно для каждого семейства. Для CatBoost дополнительно исключается по одному признаку команды с повторной внутренней настройкой оставшейся модели. Поэтому проверяется дополнительная информация при наличии остальных признаков, а не только величина отдельного коэффициента.

Улучшение определяется как $\Delta L = L_{\text{сравнение}} - L_{\text{новая}}$: положительное значение означает уменьшение ошибки. Для основной схемы сначала усредняется разность индивидуальных потерь компании между двумя повторами. Затем выполняются 2 000 парных повторных выборов компаний с возвращением и фиксированными прогнозами. Приводятся квантили 2,5% и 97,5% распределения средней разности.

Эти границы характеризуют чувствительность сравнения к составу компаний при уже полученных прогнозах. Модели при повторном выборе компаний не переобучаются; зависимость ошибок из-за общих обучающих наблюдений и возможная зависимость внутри наборов не учитываются. Поэтому границы не трактуются как полноценные доверительные интервалы качества всей процедуры обучения и не используются для формального подтверждения

702 гипотез. Отдельно рассматривается изменение результата при разделении наборов УС.

703 6.5 Объяснение прогнозов с помощью SHAP

704 Для CatBoost с набором, возрастом и двумя характеристиками команды рассчиты-
705 ваются значения SHAP. Они раскладывают исходный выход модели на базовое значение
706 и вклады признаков [2]. В бинарной задаче рассматриваемый исходный выход выражен в
707 единицах логарифма шансов:

$$\ln \frac{\hat{p}_i}{1 - \hat{p}_i} = \phi_{0,i} + \sum_{j=1}^5 \phi_{ij}.$$

708 Для каждой компании берётся модель её внешней обучающей части в первом стратифи-
709 цированном повторе. Аддитивность разложения проверяется численно. Базовые значения
710 могут различаться между внешними частями, поскольку соответствуют разным обученным
711 моделям.

712 Обобщённая важность признака представлена средним $|\phi_{ij}|$ по проверочным компа-
713 ниям. Она показывает величину его вклада в прогнозы выбранного семейства моделей, но
714 не направление связи и не изменение проверочной ошибки после удаления признака. SHAP
715 не оценивает гиперпараметры: их выбирает внутренняя проверка. Значения SHAP также не
716 интерпретируются как причинные эффекты изменения характеристик компании [16]. Они
717 используются только для объяснения уже полученных прогнозов, без последующего отбора
718 признаков в этом эксперименте.

7 Прогностическая полезность характеристик команды

В этом разделе представлены результаты первого прогнозного эксперимента: сравнение сведений о наборе и возрасте компании с добавлением размера команды и числа основателей. Исследуются 3 046 компаний УС, активных 13.07.2023, с известным статусом на 01.08.2026; положительный класс содержит 272 поглощённые или публичные компании. Все оценки получены по внешним проверочным прогнозам в соответствии с процедурой раздела 6. Они характеризуют полезность выбранных признаков для данной задачи, а не причины успеха предпринимательских инициатив.

7.1 Качество прогноза в основной схеме

В табл. 7.1 приведены метрики, усреднённые по двум стратифицированным повторам. Постоянный прогноз даёт логарифмическую потерю 0,3009. Использование только набора в логистической регрессии почти не меняет её: 0,3007. Добавление возраста снижает потерю до 0,2996, однако последующее включение двух характеристик команды увеличивает её до 0,3001. Следовательно, более подробное описание компании не приводит автоматически к лучшему вероятностному прогнозу.

Таблица 7.1: Качество внешних проверочных прогнозов для 3 046 компаний УС с известным исходом. Признаки относятся к 13.07.2023, статусы — к 01.08.2026. Представлены средние метрики двух стратифицированных повторов вложенной проверки. Для LogLoss и ошибки Брайера меньшее значение лучше; для AP и ROC-AUC — большее. ЛР обозначает логистическую регрессию.

Модель	LogLoss	AP	ROC-AUC	Брайер
Постоянный прогноз	0,3009	0,0889	0,4976	0,0813
ЛР: набор	0,3007	0,0862	0,4932	0,0813
ЛР: набор и возраст	0,2996	0,0992	0,5473	0,0812
ЛР: набор, возраст и команда	0,3001	0,0987	0,5379	0,0813
CatBoost: набор и возраст	0,2994	0,1029	0,5375	0,0811
CatBoost: набор, возраст и команда	0,2998	0,1040	0,5472	0,0812
CatBoost: без размера команды	0,2999	0,1008	0,5335	0,0812
CatBoost: без числа основателей	0,2992	0,1095	0,5622	0,0811

У CatBoost модель по набору и возрасту имеет потерю 0,2994, а модель с двумя характеристиками команды — 0,2998. Наименьшая средняя потеря среди рассмотренных вариантов равна 0,2992 и наблюдается у CatBoost без числа основателей, то есть с набором, возрастом и размером команды. Её отличие от постоянного прогноза составляет около 0,0017. Это лучшая точечная оценка в проведённом сравнении, но не доказательство превосходства такой конфигурации на новых данных.

Способность различать положительные и отрицательные исходы остаётся ограниченной. Наибольшая средняя ROC-AUC равна 0,5622, AP — 0,1095; обе оценки также относятся к CatBoost без числа основателей. Для модели с обоими признаками команды ROC-AUC составляет 0,5472, AP — 0,1040. Эти результаты не дают основания представлять модель как инструмент надёжного отбора будущих поглощённых или публичных компаний. В частности, AP не означает долю правильных ответов при определённом пороге вероятности.

Постоянный прогноз в таблице не имеет ROC-AUC строго 0,5, поскольку его вероятность одинакова внутри одной проверочной части, но определяется долей исходов в соответствующей обучающей части. При объединении внешних прогнозов эти вероятности немного различаются. Это техническое следствие процедуры оценки, а не использование моделью индивидуальных характеристик компании. Значения AP такого прогноза по той же причине не обязаны точно совпадать с общей долей положительного класса.

7.2 Дополнительная информация о команде

Парные сравнения в табл. 7.2 и на рис. 7.1 показывают изменение логарифмической потери на одинаковых проверочных компаниях. Знак определён так, что положительная разность означает улучшение новой модели. Добавление возраста к набору в логистической регрессии даёт среднее улучшение 0,00108. Добавление команды к набору и возрасту, напротив, ухудшает среднюю оценку на 0,00045 для логистической регрессии и на 0,00046 для CatBoost.


Таблица 7.2: Парные изменения логарифмической потери в основной проверке по 3 046 компаниям УС. Положительное значение означает уменьшение ошибки. Границы получены повторным выбором компаний при фиксированных прогнозах и не являются полной оценкой неопределённости процедуры обучения.

Сравнение	ΔL	Условные границы
Возраст сверх набора, ЛР	0,00108	[-0,00043; 0,00246]
Команда сверх возраста и набора, ЛР	-0,00045	[-0,00117; 0,00024]
Команда сверх возраста и набора, CatBoost	-0,00046	[-0,00224; 0,00121]
Размер команды при известном числе основателей	0,00004	[-0,00147; 0,00151]
Число основателей при известном размере команды	-0,00064	[-0,00167; 0,00030]
CatBoost против ЛР на одинаковых признаках	0,00021	[-0,00173; 0,00216]

Исключение признаков по отдельности уточняет результат для CatBoost. Добавление размера команды при уже известном числе основателей даёт практически нулевую среднюю

Изменение ошибки при добавлении признаков и смене модели

УС: 3 046 компаний, активных 13.07.2023; статус на 01.08.2026 известен.



ЛР — логистическая регрессия; команда — размер и число основателей. Парные разности потерь усреднены по двум повторам. Отрезки — центральные 95% из 2000 повторных выборок компаний при фиксированных прогнозах. Переобучение и зависимость внутри наборов не учтены; это не полная неопределённость процедуры. Положительный исход: поглощение или публичный статус. Источник: расчёты по сопоставленным выгрузкам каталога УС на Kaggle.

Рис. 7.1: Изменение проверочной логарифмической потери при добавлении признаков и замене алгоритма для компаний УС, активных 13.07.2023, с известным статусом на 01.08.2026 ($n = 3\,046$). Точка — средняя парная разность двух стратифицированных повторов; значения справа от нуля означают улучшение. Отрезки охватывают центральные 95% из 2 000 повторных выборок компаний при фиксированных прогнозах, без переобучения моделей и учёта зависимости внутри наборов.

разность: 0,00004. Добавление числа основателей при известном размере команды ухудшает среднюю потерю на 0,00064. Следовательно, в рассмотренных конфигурациях число основателей не даёт убедительного дополнительного улучшения; однако это не доказывает его бесполезности при других представлениях, алгоритмах или исходах.

Во всех шести сравнениях основной схемы условные границы охватывают ноль. С учётом ограничений их расчёта это не заменяет формальной проверки гипотез, но показывает, что небольшие средние различия не следует интерпретировать как точный рейтинг признаков. Неустойчивость заметна и между двумя повторами: добавление команды в CatBoost увеличивает потерю примерно на 0,00129 в первом повторе и уменьшает на 0,00037 во втором. Среднее скрывает смену направления различия.

Таким образом, наблюдавшиеся в EDA различия размера команды между группами позднего статуса не превратились в устойчивое улучшение прогноза после учёта возраста и набора. Групповое различие и дополнительная прогностическая информация являются разными результатами исследования.

7.3 Проверка с разделением наборов УС

В дополнительной схеме компании одного набора не встречаются одновременно в обучении и проверке. Результаты приведены в табл. 7.3; рис. 7.2 сопоставляет логарифмические потери двух схем. Внешние проверочные части содержат от 584 до 655 компаний и от 51 до 57 положительных исходов, то есть различия не сводятся к отсутствию положительного класса в какой-либо части.

Таблица 7.3: Качество прогнозов с разделением по полному коду набора УС: один повтор вложенной проверки, 3 046 компаний с известным статусом на 01.08.2026 и исходными признаками на 13.07.2023. Каждый набор целиком отнесён к одной внешней части; внутри обучения разделение по наборам сохранено. Направления улучшения метрик совпадают с табл. 7.1.

Модель	LogLoss	AP	ROC-AUC	Брайер
Постоянный прогноз	0,3011	0,0844	0,4755	0,0814
ЛР: набор	0,3017	0,0814	0,4679	0,0815
ЛР: набор и возраст	0,3018	0,0900	0,5078	0,0816
ЛР: набор, возраст и команда	0,3021	0,0904	0,5102	0,0816
CatBoost: набор и возраст	0,3000	0,0952	0,5154	0,0812
CatBoost: набор, возраст и команда	0,2998	0,0966	0,5294	0,0812
CatBoost: без размера команды	0,3007	0,0913	0,5061	0,0813
CatBoost: без числа основателей	0,2997	0,0993	0,5320	0,0812

При разделении наборов постоянный прогноз имеет потерю 0,3011. Логистическая регрессия с возрастом и командой даёт 0,3021, то есть оказывается хуже этого ориентира.

Ошибка вероятностного прогноза при двух схемах проверки

УС: 3 046 компаний, активных 13.07.2023; статус на 01.08.2026 известен.




Рис. 7.2: Логарифмическая потеря восьми вариантов прогноза статуса на 01.08.2026 по характеристикам компаний УС на 13.07.2023 ($n = 3\,046$ с известным исходом). Круги — среднее двух стратифицированных повторов, квадраты — проверка с разделением наборов УС. Меньшее значение означает лучший вероятностный прогноз. Все точки получены по внешним проверочным наблюдениям; разделение наборов не является проверкой нового календарного периода.

CatBoost с теми же признаками имеет потерю 0,2998 и превосходит соответствующую логистическую регрессию примерно на 0,0023. Однако относительно CatBoost только по набору и возрасту выигрыш от добавления команды составляет лишь 0,00021; в основной схеме знак этого сравнения был противоположным.

Ранжирование также ухудшается относительно основной схемы: у CatBoost с двумя характеристиками команды ROC-AUC составляет 0,5294, AP — 0,0966. У варианта без числа основателей эти показатели равны 0,5320 и 0,0993. Это указывает на ограниченную переносимость обнаруженных зависимостей между наборами в рамках проведённой проверки. Одного группового разбиения недостаточно для общей оценки всех возможных различий между наборами, а тем более для вывода о качестве прогнозирования после августа 2026 года.

7.4 Вероятности и наблюдаемые частоты


Рисунок 7.3 сопоставляет средние проверочные вероятности с фактическими долями положительного класса в группах примерно одинакового размера. Для всех трёх моделей использован первый стратифицированный повтор, выбранный до сравнения результатов. Границы групп определяются отдельно по прогнозам каждой модели; принадлежность компании к группам разных моделей поэтому может различаться.

Для CatBoost с возрастом и командой средняя предсказанная вероятность в нижней группе составляет 6,00%, тогда как наблюдаемая доля положительного исхода — 7,52%. В верхней группе эти значения равны 11,31% и 9,69%. В данном повторе модель раздвигает средние вероятности крайних групп сильнее, чем различаются наблюдаемые частоты. При этом наибольшая фактическая доля наблюдается не в верхней группе вероятности, а в предпоследней: 10,20%.

У логистической регрессии с теми же признаками крайние группы имеют средние вероятности 6,48% и 11,35% при наблюдаемых долях 6,39% и 10,84%. Такое совпадение в отдельных группах не означает достаточного разделения исходов: большинство предсказаний остаётся близко к общей частоте положительного класса. Кроме того, небольшие различия групповых частот подвержены случайным колебаниям. По пяти точкам одного повтора нельзя установить систематическую ошибку калибровки либо выбрать способ её исправления без дополнительной проверки.

Предсказанные вероятности и наблюдаемые частоты исхода

УС: 3 046 компаний, активных 13.07.2023; статус на 01.08.2026 известен.



Первый стратифицированный повтор; только проверочные прогнозы. Точки — группы примерно равного размера по вероятности, границы определены отдельно для каждой модели. Линии соединяют точки; дополнительная калибровка моделей не выполнялась. Положительный исход: поглощение или публичный статус. Источник: расчёты по сопоставленным выгрузкам каталога УС на Kaggle.


Рис. 7.3: Средние вероятности и наблюдаемые доли поглощённых или публичных компаний на 01.08.2026 среди исходно активных компаний УС ($n = 3\,046$). Показаны внешние проверочные прогнозы первого стратифицированного повтора по признакам на 13.07.2023. Каждая точка объединяет примерно пятую часть компаний по предсказанной вероятности конкретной модели. Пунктир соответствует совпадению средней вероятности и наблюдаемой частоты; дополнительная калибровка не выполнялась.

7.5 Вклад признаков в прогнозы CatBoost

На рис. 7.4 представлены средние модули SHAP для CatBoost с пятью исходными признаками. Каждая компания объясняется моделью, для которой она была внешним проверочным наблюдением. Поэтому рисунок не основан на объяснении обучающих прогнозов, но остаётся описанием поведения уже выбранного семейства моделей.

Вклад признаков в проверочные прогнозы CatBoost

УС: 3 046 компаний, активных 13.07.2023; статус на 01.08.2026 известен.



CatBoost с набором, возрастом и командой; первый стратифицированный повтор. Для каждой компании объясняется модель, не обучавшаяся на ней. Модуль SHAP не показывает направление связи, причинный эффект или улучшение проверочного качества. Положительный исход: поглощение или публичный статус. Источник: расчёты по сопоставленным выгрузкам каталога УС на Kaggle.

Рис. 7.4: Средние абсолютные вклады SHAP в проверочные прогнозы CatBoost для 3 046 компаний УС с известным статусом на 01.08.2026. Используются признаки на 13.07.2023 и пять внешних моделей первого стратифицированного повтора. Единица вклада — логарифм шансов положительного статуса, а не процент вероятности. Длина столбца не показывает направление связи, причинный эффект или улучшение качества после добавления признака.

Наибольший средний модуль вклада имеет логарифм размера команды — 0,0831. Далее следуют год набора (0,0719), возраст (0,0656), число основателей (0,0521) и сезон набора (0,0315). Эти числа характеризуют изменение исходного выхода модели относительно её базового значения при разложении SHAP. Они не являются коэффициентами логистической регрессии и не означают, например, увеличение вероятности на 8,31 процентного пункта из-за размера команды.

Результат особенно важен в сопоставлении с исключением признаков: размер команды имеет наибольший средний вклад в прогнозы, однако его добавление при известном числе основателей почти не меняет среднюю проверочную потерю. Признак может заметно влиять на ответы модели, не обеспечивая устойчивого улучшения этих ответов относительно мо-

дели без него. Возможны дублирование информации другими признаками и использование зависимостей, недостаточно устойчивых вне обучения; проведённое сравнение не позволяет однозначно выбрать одно объяснение.

Следовательно, рейтинг SHAP не заменяет проверку дополнительной полезности. На этом этапе нельзя называть размер команды главным доказанным предиктором успеха только потому, что его столбец самый длинный. Корректный вывод уже: в рассмотренном CatBoost этот признак сильнее остальных в среднем участвует в формировании проверочных прогнозов.

7.6 Выводы первого эксперимента

Проверка не выявила устойчивого улучшения вероятностного прогноза от совместного добавления размера команды и числа основателей к набору и возрасту. Между алгоритмами и схемами оценки есть различия, но абсолютное качество ранжирования остаётся невысоким. Лучшие точечные оценки принадлежат CatBoost без числа основателей; считать этот вариант окончательно выбранной моделью на основании текущих результатов преждевременно.

Результат уточняет смысл описательных зависимостей: различия между группами следующего статуса не гарантируют полезности для прогноза отдельной компании. Он также показывает, почему объяснение модели через SHAP должно сопровождаться сравнением проверочного качества.

Вывод ограничен выбранным показателем, когортой с известным исходом, пятью характеристиками и заданными конфигурациями моделей. Пока не проверены география, тематические теги, текстовое представление деятельности, альтернативная обработка сомнительных нулевых значений и влияние семи публичных компаний на объединённый положительный класс. Их исследование должно продолжать зафиксированную процедуру сравнения, а не служить поиском отдельного удачного результата. Новое изменение модели после просмотра этих оценок потребует явно учитывать исследовательский характер такого выбора.

8 Корреляционный анализ

Для количественной оценки связи признаков с успехом стартапа был проведен корреляционный анализ (Рис. 8.1). Бинарная переменная `success` (1 = success, 0 = failure) была сопоставлена с числовыми признаками, не подверженными ошибке выжившего: `is_solo_founder`, `tag_count` и `desc_length`. Для расчета использовался коэффициент корреляции Пирсона [11].




Рис. 8.1: Матрица корреляций и корреляция признаков с успехом

Результаты показали следующие значения корреляции с успехом:

- `is_solo_founder`: $r = -0.11$ — отрицательная корреляция, подтверждающая, что соло-основатели менее успешны
- `desc_length`: $r = 0.09$ — слабая положительная корреляция, согласующаяся с наблюдением о преимуществе умеренно длинных описаний
- `tag_count`: $r = 0.04$ — очень слабая положительная корреляция, объяснимая нелинейным характером зависимости

Между самими признаками наблюдается умеренная корреляция `tag_count` и `desc_length` ($r = 0.24$). Действительно, компании с более подробным описанием склонны указывать больше тегов. Признак `is_solo_founder` слабо отрицательно коррелирует с `tag_count` ($r = -0.10$), что может свидетельствовать о том, что основатели-одиночки чаще фокусируются на узкой нише.

Важно отметить, что линейная корреляция Пирсона не улавливает нелинейные зависимости, выявленные в гипотезах H4 и H5. Перевернутая U-образная зависимость между количеством тегов и успехом проявляется как слабая линейная корреляция ($r = 0.04$), хотя реальная связь существенна. Это подчеркивает важность визуального анализа в дополнение к числовым метрикам.

9 Анализ динамики (2023–2025)

Для анализа динамики использовался Датасет В, содержащий 4202 компании, присутствующие в обоих временных срезах.

9.1 Матрица переходов статусов

Матрица переходов (Рис. 9.1) показывает, как изменились статусы компаний за два года. Основные наблюдения:

- 2468 компаний сохранили статус active
- 233 компания перешла из active в acquired, 7 — в public (итого 228 новых успешных случаев)
- 346 компаний перешли из active в inactive (закрылись)
- 627 компаний сохранили статус inactive, 499 — acquired, 16 — public
- Обратные переходы (из inactive в active или acquired) единичны (1 и 2 соответственно)




Рис. 9.1: Матрица переходов статусов (2023 – 2025)

Из матрицы переходов следует, что за два года из 3054 активных компаний 233 (7.6%) достигли exit, а 346 (11.3%) закрылись. Таким образом, соотношение «закрытий» к «успехам» составляет примерно 1.5:1, что согласуется с общей статистикой венчурного рынка.

9.2 Динамика размера команды

Анализ изменения размера команды (Рис. 9.2) показал, что компании, достигшие успеха к 2025 году, чаще увеличивали размер команды по сравнению с неуспешными. Доля компаний, увеличивших команду, составляет около 11.1% среди успешных и около 4.2% среди неуспешных.




Рис. 9.2: Динамика размера команды и успех (2023 – 2025)

Это наблюдение согласуется с результатами гипотезы Н6 (найм как сигнал): рост команды является индикатором активного развития компании и коррелирует с достижением «успеха». При этом важно отметить, что рост команды может быть как причиной, так и следствием успеха (привлечение инвестиций позволяет нанимать больше сотрудников).

10 Выводы и рекомендации

10.1 Основные результаты

В ходе эмпирического исследования данных о 5739 стартапах — выпускниках акселератора Y Combinator — были проверены восемь гипотез о предикторах успеха с контролем по когортам для исключения ошибки выжившего. Основные результаты:

- 1 **Тип команды основателей** (H1): наличие нескольких основателей положительно связано с успехом. Соло-основатели имеют долю успеха 35.1%, пары — 45.7%, команды 3+ — 50.9%. Различие статистически значимо ($p < 0.05$) и устойчиво при контроле по когортам. Корреляция `is_solo_founder` с успехом: $r = -0.11$.
- 2 **Отрасль** (H2): B2B-стартапы имеют значимо более высокую долю успеха (49.1%) по сравнению с Consumer (32.9%). Различие устойчиво во всех когортах 2005–2025 годов, что свидетельствует о структурном преимуществе B2B-модели.
- 3 **Сезон батча** (H3): не является значимым предиктором. Summer (42.5%) и Winter (44.1%) показывают практически одинаковые результаты. Это важный «нулевой результат», исключаящий сезонность как фактор.
- 4 **Лаконичность описания** (H4): зависимость нелинейная. Оптимальная длина описания — средняя (квартили Q2–Q3, доля успешных $\approx 48.5\%$). Как слишком короткие, так и слишком длинные описания связаны с более низкой долей успеха ($\approx 41\%$).
- 5 **Количество тегов** (H5): зависимость имеет перевернутую U-образную форму. Оптимум — 3–4 тега (48.2%). Отсутствие тегов (36.3%) и избыток 5+ (37.6%) связаны с более низким успехом. Это свидетельствует о важности четкого, но не чрезмерно узкого позиционирования.
- 6 **Активный найм** (H6): сильнейший индикатор ($\approx 100\%$ среди нанимающих), однако является скорее маркером текущего состояния, чем предиктором. Неактивные компании по определению не нанимают.
- 7 **География** (H7): преимущество США невелико (45.6% vs 41.8%) и может объясняться особенностями выборки.
- 8 **Стадия развития** (H8): Growth-стартапы имеют долю успеха 75.8% против 37.2% у Early. Различие устойчиво по когортам, но стадия частично отражает уже достигнутый прогресс.

10.2 Методологический вклад

Ключевым методологическим вкладом данной работы является демонстрация важности контроля по когортам при анализе предикторов успеха стартапов. Наивное сравнение по возрасту компании или размеру команды приводит к тривиальным и вводящим в заблуждение выводам («старые компании успешнее», «большие команды успешнее»), которые являются проявлением ошибки выжившего. Фокус на характеристиках, известных на момент входа в акселератор, и контроль по году батча позволяют выявить действительно информативные предикторы.

10.3 Ограничения исследования

- Данные ограничены выпускниками одного акселератора (Y Combinator), что может не отражать общую картину венчурного рынка.
- Значительная доля компаний (69%) имеет статус active, что означает, что их итоговый исход еще неизвестен.
- Корреляция не означает причинно-следственную связь: например, стадия Growth может быть как причиной, так и следствием успеха.
- Пропуски в данных (особенно `year_founded` — 44.9%, `country` — 29%) могут вносить смещение в результаты.
- Определение «успеха» как `acquired` + `public` является упрощением: не все поглощения являются успешными для основателей.
- Некоторые признаки (`isHiring`, `stage`) отражают текущее состояние компании, а не характеристику на момент входа в акселератор.
- Нелинейные зависимости (H4, H5) плохо улавливаются линейной корреляцией Пирсона.

10.4 Рекомендации

На основе полученных результатов можно сформулировать следующие практические рекомендации:

- Для предпринимателей:

- 956 – Формирование команды из нескольких основателей (2–3 человека) повышает шан-
957 сы на успех на 10–15 процентных пунктов по сравнению с соло-основательством.
- 958 – Четкое позиционирование (3–4 тега, умеренно лаконичное описание) связано с бо-
959 лее высокой долей успеха.
- 960 – B2B-модель демонстрирует структурное преимущество перед Consumer.

961 • **Для инвесторов:**

- 962 – При оценке стартапов стоит обращать внимание на тип команды основателей и
963 отрасль как на наиболее надежные предикторы, не подверженные ошибке выжив-
964 шего.
- 965 – Активный найм и стадия Growth являются полезными индикаторами текущего
966 состояния портфельных компаний.
- 967 – Сезон батча и география (в рамках УС) не являются значимыми факторами.

968 • **Для исследователей:**

- 969 – Контроль по когортам является необходимым условием корректного анализа пре-
970 дикторов успеха.
- 971 – Нелинейные зависимости требуют визуального анализа в дополнение к числовым
972 метрикам.
- 973 – Полученные результаты могут служить основой для более глубокого анализа с
974 использованием дополнительных источников данных.

Список литературы

- [1] Albert V. Bruno, Edward F. McQuarrie и Carol G. Torgrimson. “The evolution of new technology ventures over 20 years: Patterns of failure, merger, and survival”. В: *Journal of Business Venturing* 7.4 (1992), с. 291—302. DOI: [10.1016/0883-9026\(92\)90003-A](https://doi.org/10.1016/0883-9026(92)90003-A).
- [2] CatBoost developers. *ShapValues*. URL: <https://catboost.ai/docs/en/concepts/shap-values> (дата обр. 13.09.2026).
- [3] GetInvestor. *Crunchbase — что это такое и как пользоваться*. 2024. URL: <https://get-investor.ru/crunchbase-chem-polezen-startapu> (дата обр. 30.01.2025).
- [4] Paul A. Gompers, Will Gornall, Steven N. Kaplan и Ilya A. Strebulaev. *How Do Venture Capitalists Make Decisions?* Working Paper 22587. National Bureau of Economic Research, 2016. DOI: [10.3386/w22587](https://doi.org/10.3386/w22587). URL: <https://www.nber.org/papers/w22587>.
- [5] Kaggle. *Y Combinator Companies Dataset*. 2026. URL: <https://www.kaggle.com/datasets/nitishraj/ycombinatorcompanies> (дата обр. 14.09.2026).
- [6] Kaggle. *Y Combinator Directory*. 2023. URL: <https://www.kaggle.com/datasets/miguelcorraljr/y-combinator-directory> (дата обр. 14.09.2026).
- [7] Ulrich Kaiser и Johan Moritz Kuhn. *The Value of Publicly Available, Textual and Non-textual Information for Startup Performance Prediction*. Discussion Paper 13029. IZA Institute of Labor Economics, 2020. URL: <https://docs.iza.org/dp13029.pdf>.
- [8] Ulrich Kaiser и Johan Moritz Kuhn. “The Value of Publicly Available, Textual and Non-textual Information for Startup Performance Prediction”. В: *Journal of Business Venturing Insights* 14, e00179 (2020). DOI: [10.1016/j.jbvi.2020.e00179](https://doi.org/10.1016/j.jbvi.2020.e00179).
- [9] Sayash Kapoor и Arvind Narayanan. “Leakage and the reproducibility crisis in machine-learning-based science”. В: *Patterns* 4.9, 100804 (2023). DOI: [10.1016/j.patter.2023.100804](https://doi.org/10.1016/j.patter.2023.100804).
- [10] Henry B. Mann и Donald R. Whitney. “On a test of whether one of two random variables is stochastically larger than the other”. В: *The Annals of Mathematical Statistics* 18.1 (1947), с. 50—60.
- [11] Karl Pearson. “Notes on regression and inheritance in the case of two parents”. В: *Proceedings of the Royal Society of London* 58 (1895), с. 240—242.

- [12] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush и Andrey Gulin. *CatBoost: unbiased boosting with categorical features*. 2019. arXiv: [1706.09516](https://arxiv.org/abs/1706.09516). URL: <https://arxiv.org/abs/1706.09516> (дата обр. 13.09.2026).
- [13] Greg Ross, Sanjiv Ranjan Das, Daniel Sciro и Hussain Raza. “CapitalVX: A machine learning model for startup selection and exit prediction”. B: *The Journal of Finance and Data Science* 7 (2021), с. 94—114. DOI: [10.1016/j.jfds.2021.04.001](https://doi.org/10.1016/j.jfds.2021.04.001).
- [14] scikit-learn developers. *Metrics and scoring: quantifying the quality of predictions*. URL: https://scikit-learn.org/stable/modules/model_evaluation.html (дата обр. 13.09.2026).
- [15] scikit-learn developers. *Nested versus non-nested cross-validation*. URL: https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html (дата обр. 13.09.2026).
- [16] SHAP developers. *Be careful when interpreting predictive models in search of causal insights*. URL: https://shap.readthedocs.io/en/latest/example_notebooks/overviews/Be%20careful%20when%20interpreting%20predictive%20models%20in%20search%20of%20causal%20insights.html (дата обр. 13.09.2026).
- [17] Boris Sharchilev, Michael Roizner, Andrey Rumyantsev, Denis Ozornin, Pavel Serdyukov и Maarten de Rijke. “Web-based Startup Success Prediction”. B: *Proceedings of the 27th ACM International Conference on Information and Knowledge Management*. ACM, 2018. DOI: [10.1145/3269206.3272011](https://doi.org/10.1145/3269206.3272011). URL: <https://staff.fnwi.uva.nl/m.derijke/wp-content/papercite-data/pdf/sharchilev-web-based-2018.pdf>.
- [18] Galit Shmueli. “To Explain or to Predict?” B: *Statistical Science* 25.3 (2010), с. 289—310. DOI: [10.1214/10-STS330](https://doi.org/10.1214/10-STS330).
- [19] Wikipedia. *Kaggle*. 2024. URL: <https://ru.wikipedia.org/wiki/Kaggle> (дата обр. 30.01.2025).
- [20] Wikipedia. *Разведочный анализ данных*. 2024. URL: https://ru.wikipedia.org/wiki/%D0%A0%D0%B0%D0%B7%D0%B2%D0%B5%D0%B4%D0%BE%D1%87%D0%BD%D1%8B%D0%B9_%D0%B0%D0%BD%D0%B0%D0%BB%D0%B8%D0%B7_%D0%B4%D0%B0%D0%BD%D0%BD%D1%8B%D1%85 (дата обр. 30.01.2025).
- [21] Y Combinator. *The YC Startup Directory*. URL: <https://www.ycombinator.com/companies> (дата обр. 10.09.2026).

- 1035 [22] Y Combinator. *Y Combinator*. 2025. URL: <https://www.ycombinator.com/> (дата обр.
1036 10.02.2025).
- 1037 [23] ВТБ. *Что такое стартап*. 2024. URL: [https://vtb.ru/articles/что-такое-
1038 startup/](https://vtb.ru/articles/что-такое-startap/) (дата обр. 30.01.2025).
- 1039 [24] РБК. *Что такое IPO: как компания выходит на биржу*. 2022. URL: [https://www.rbc.
1040 ru/quote/news/training/5e25ceaf9a79471671787078](https://www.rbc.ru/quote/news/training/5e25ceaf9a79471671787078) (дата обр. 25.03.2025).