

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.89:330.4

Отчёт об исследовательском проекте на тему:
Эмпирическое исследование и визуализация ключевых предикторов успеха
предпринимательских инициатив

Выполнил студент:

группы #БПМИ232, 3 курса

Бородатов Егор Олегович

Принял руководитель проекта:

Иванов Андрей Александрович

Доцент

Базовая кафедра Т-Банка

Содержание

Аннотация	5
1 Основные термины и определения	6
2 Введение	6
2.1 Актуальность работы	6
2.2 Цель	7
2.3 Объект исследования	8
2.4 Предмет исследования	9
2.5 Методы исследования	9
2.5.1 Методы предобработки данных	9
2.5.2 Разведочный анализ данных (EDA)	9
2.5.3 Статистический анализ и прогнозное моделирование	9
2.5.4 Инструменты визуализации	10
2.6 Задачи	10
2.7 План работы	11
2.8 Использование генеративных моделей	11
3 Обзор литературы	13
3.1 Определение результата	13
3.2 Характеристики компаний и прогнозный анализ	13
3.3 Публичные сведения и текстовые признаки	14
3.4 Время наблюдения и проверка качества	15
4 Описание данных	16
4.1 Источники и даты наблюдения	16
4.2 Поля исходных файлов	18
4.3 Формирование исследуемой группы и производные поля	20
4.4 Последующий статус и границы наблюдения	22
4.5 Проверки и воспроизводимость	22
5 Разведочный анализ данных	23
5.1 Формирование исследуемой совокупности	23
5.2 Полнота исходных характеристик	23

5.3	Последующие статусы и наблюдаемый показатель успеха	24
5.4	Годы набора и доступность последующих статусов	26
5.5	Распределения числовых характеристик	27
5.6	Исходный размер команды в группах последующего статуса	28
5.7	Зависимости между исходными числовыми признаками	29
5.8	Географический состав	31
5.9	Тематические теги исходных карточек	32
6	Методология прогнозного анализа	34
6.1	Прогнозируемый исход	34
6.2	Блоки признаков и модели	34
6.3	Учёт дисбаланса классов	35
6.4	Схема проверки	35
6.5	Метрики качества	36
6.6	Сравнение признаков и неопределённость	37
6.7	Интерпретация и проверки чувствительности	37
7	Прогностическая полезность характеристик компаний	39
7.1	Качество вероятностного прогноза	39
7.2	Разнообразие разбиений и разброс результатов	41
7.3	Добавление и исключение блоков признаков	41
7.4	Ранжирование редкого исхода и веса классов	44
7.5	Соответствие вероятностей наблюдаемым частотам	47
7.6	Интерпретация тематических меток	48
7.7	Вспомогательное объяснение CatBoost	48
7.8	Чувствительность к составу совокупности и исхода	50
7.9	Выводы прогнозного эксперимента	51
8	Заключение	52
8.1	Выполненные задачи	52
8.2	Основные результаты	52
8.3	Ограничения исследования	53
8.4	Выводы и рекомендации	54
9	Описание применения генеративных моделей	56

Список литературы	58
А Первоначальный план проекта	61

Аннотация

Работа посвящена оценке прогностической полезности блоков открытых характеристик компаний Y Combinator. Исследуемую совокупность составили 3 110 компаний, активных 13 июля 2023 года. Их характеристики сопоставлены со статусами в августовской версии каталога 2026 года, скачанной автором в середине августа. Для 3 046 компаний последующий статус известен; 272 из них поглощены или имеют публичный статус.

Описаны происхождение и ограничения данных, выполнены предобработка и разведочный анализ. Постоянный прогноз, регуляризованная логистическая регрессия и CatBoost сопоставлены во вложенной перекрёстной проверке с пятью групповыми и пятью случайными повторами. Оценены добавление и исключение блоков, ранжирование редкого исхода, веса классов при одинаковом критерии настройки и чувствительность к исключению ИК12 и публичных компаний. Для парных изменений ошибки приведены условные диапазоны повторных выборок компаний и целых наборов.

Полная логистическая модель имеет LogLoss 0,2958, что на 1,75% меньше потери постоянного прогноза. ROC-AUC составляет 0,6154, AP — 0,1402 при частоте положительного класса 0,0893. Добавление тематических меток к модели с набором, возрастом и командой уменьшает LogLoss на 0,00510. Результат указывает на ограниченный прогностический сигнал и остаётся разведочным. Условные диапазоны не учитывают переобучение; независимая внешняя проверка и оценка практической полезности не выполнены. Выводы не интерпретируются как причинные эффекты или готовые рекомендации по отбору компаний.

Ключевые слова

Стартапы, Y Combinator, прогнозирование, бинарная классификация, логистическая регрессия, CatBoost, тематические метки, вложенная перекрёстная проверка, разведочный анализ данных

1 Основные термины и определения

- **Стартап** — молодая компания, находящаяся на стадии развития и строящая бизнес вокруг инновационной технологии, идеи или новой бизнес-модели [23].
- **Предиктор наблюдаемого исхода** — характеристика, известная на момент составления прогноза и оцениваемая по способности улучшать качество на данных, не использованных при обучении модели.
- **Y Combinator** — один из крупнейших и наиболее известных стартап-акселераторов в мире, основанный в 2005 году. Среди выпускников — Airbnb, Dropbox, Stripe, Reddit и другие [22].
- **Набор Y Combinator** — группа компаний, принятых в акселератор в один период времени.
- **Kaggle** — публичная веб-платформа, на которой пользователи и организации могут публиковать наборы данных, исследовать их и создавать модели [19].
- **Разведочный анализ данных** — исследование основных свойств данных, их распределений, взаимосвязей и аномалий, часто выполняемое с помощью визуализации [20].
- **Ошибка выжившего** — систематическая ошибка отбора, возникающая, когда выводы строятся только по объектам, прошедшим некоторый отбор, а выбывшие объекты не наблюдаются. Известный пример относится к анализу повреждений самолётов, вернувшихся с боевых вылетов во время Второй мировой войны. Пробоины на вернувшихся самолётах указывали на участки, повреждение которых было совместимо с возвращением, поэтому усиливать следовало не наиболее повреждённые, а менее повреждённые зоны, попадания в которые чаще приводили к потере самолёта [10].
- **Crunchbase** — онлайн-платформа со сведениями о компаниях, инвесторах и предпринимателях [3].

2 Введение

2.1 Актуальность работы

Выбор компаний для инвестирования предполагает оценку их перспектив по сведениям, доступным до получения результата. В работе [4] по результатам опроса венчурных

инвесторов показано, что при отборе компаний существенное значение придаётся характеристикам команды и бизнеса. Это придаёт прикладной смысл исследованию предикторов успеха: важно установить, какие наблюдаемые характеристики действительно помогают прогнозировать последующие результаты, а не только учитываются участниками рынка при принятии решений. Сам по себе опрос предпочтений инвесторов на этот вопрос не отвечает.

Различие между признаками, которым придают значение, и признаками, полезными для прогноза, определяет аналитическую проблему работы. В работе [18] показано, что объяснение наблюдаемых зависимостей и прогнозирование новых наблюдений являются разными задачами: убедительность объяснительной модели не гарантирует её предсказательного качества. Поэтому содержательные предположения о роли команды, географии или направления деятельности нуждаются в самостоятельной прогностической проверке. Для исследования ключевых предикторов существенен не только факт связи признака с результатом, но и то, улучшает ли этот признак прогноз по сравнению с более простой моделью.

Открытые сведения позволяют поставить этот вопрос применительно к конкретному источнику данных. Каталог Y Combinator содержит карточки компаний со сведениями об их деятельности, командах и статусах [21]; на Kaggle опубликованы загрузки этого каталога [6, 5]. Доступность таких записей создаёт возможность эмпирической проверки, но сама по себе не подтверждает их пригодность для прогнозирования. С учётом разграничения описательного и прогностического анализа [18] в данной работе проверяется, какую дополнительную информацию о последующем статусе компаний дают характеристики их публичных карточек сверх года и сезона набора УС и возраста компании.

Таким образом, работа связывает два вопроса: какие характеристики компаний рассматриваются при оценке их перспектив [4] и какие из доступных характеристик выдерживают проверку на прогностическую полезность [18]. Её предполагаемый вклад состоит в оценке дополнительной информативности сведений о команде, географии и деятельности компаний УС, а также в наглядном представлении надёжности полученных различий. Такой результат позволит судить о возможностях конкретного источника данных для прогнозирования наблюдаемого показателя успеха, а не предлагать универсальный перечень условий успешного предпринимательства.

2.2 Цель

Целью работы является оценка и визуализация прогностической полезности блоков открытых характеристик компаний Y Combinator, а также устойчивости их вклада в прогноз

последующего статуса. Интерпретация отдельных тематических меток служит дополнительным разведочным результатом.

Успех в рамках исследования определяется как наличие статуса поглощённой или публичной компании в августовской версии каталога 2026 года у компании, активной на начало наблюдения. Такое объединение выделяет два наблюдаемых корпоративных события, однако служит лишь приближённым показателем успеха: данные о статусе не позволяют оценить доходность для владельцев, а поглощение не обязательно означает выгодную продажу. Поэтому наряду с объединённым показателем рассматривается состав положительного класса. Продолжение деятельности и неактивность означают отсутствие данного показателя в позднем срезе, но не трактуются как равнозначные экономические результаты.

Предикторами выступают характеристики, зафиксированные на начало периода наблюдения, а полезность их блоков оценивается по улучшению прогноза на данных, не использованных при обучении и настройке модели. Устойчивость отдельных коэффициентов не приравнивается к доказательству полезности отдельного признака. Исследование оценивает прогностические связи, а не причинные эффекты; его выводы характеризуют полезность доступных сведений для прогноза, а не способы обеспечить успех компании.

2.3 Объект исследования

Объектом исследования являются компании каталога УС, имевшие активный статус в выгрузке от 13 июля 2023 года. Единицей наблюдения служит компания с уникальным идентификатором. Её характеристики на эту дату сопоставляются со статусом в августовской версии позднего датасета 2026 года; срез от 27 февраля 2023 года используется для проверки согласованности сведений. Анализируются сторонние выгрузки каталога, размещённые на Kaggle, а не данные, собранные автором непосредственно с сайта УС.

Состав исследуемой совокупности определяется по июльскому срезу. Компании, отсутствующие в поздней выгрузке, сохраняются в учёте как записи с неизвестным последующим состоянием. Период сопоставления охватывает интервал с июля 2023 года по августовскую версию 2026 года, то есть немногим более трёх лет. Прогнозируется статус, зафиксированный в конечном срезе; точные даты переходов между состояниями по этим данным не определяются.

Выводы относятся к компаниям, активным на начало наблюдения. Измеренные характеристики отражают их состояние в июле 2023 года, а не обязательно на момент основания или поступления в акселератор. Поэтому результаты не переносятся автоматически на вновь

созданные компании и предпринимательские инициативы вне УС.

2.4 Предмет исследования

Предметом исследования являются прогностические связи между характеристиками компаний на 13 июля 2023 года и их статусами в августовской версии 2026 года, а также вклад отдельных характеристик и их групп в качество прогноза наблюдаемого показателя успеха. Рассматриваются число основателей, размер команды, год основания, год и сезон набора УС, география, тематические теги и текстовые описания.

2.5 Методы исследования

2.5.1 Методы предобработки данных

Подготовка данных предусматривает проверку идентификаторов, устранение дубликатов, согласование форматов и сопоставление записей между срезами. Пропуски в признаках отделяются от неизвестных последующих состояний. Поздние значения не используются для восстановления характеристик на начало наблюдения; преобразования, параметры которых оцениваются по данным, настраиваются только на обучающей части выборки [9].

2.5.2 Разведочный анализ данных (EDA)

Разведочный анализ охватывает полноту данных, распределения характеристик, частоты статусов и связи между признаками. Отдельно сопоставляются компании разных годов набора и компании с известным и неизвестным последующим состоянием. Описательная статистика и графики служат для выявления особенностей выборки и ограничений дальнейшего моделирования.

2.5.3 Статистический анализ и прогнозное моделирование

Основной метод анализа — сравнение моделей бинарной классификации наблюдаемого показателя успеха. Предусматривается сопоставление простых прогнозов, включая модель по году и сезону набора и возрасту, с регуляризованной логистической регрессией и градиентным бустингом. Вклад групп признаков оценивается по изменению качества при их добавлении и исключении на одинаковых проверочных разбиениях.

Оценка качества бинарной классификации включает точность вероятностного прогноза и способность модели отделять редкий положительный класс от отрицательного. Настрой-

ка гиперпараметров выполняется внутри обучающих частей, а качество рассчитывается на не использованных при настройке наблюдениях. Для парных различий логарифмической потери приводится диапазон, полученный при 2 000 повторных выборках компаний и целых наборов УС. Дополнительно сравниваются результаты случайного стратифицированного разделения и разделения, при котором компании одного набора Y Combinator не попадают одновременно в обучение и проверку.

2.5.4 Инструменты визуализации

Для визуализации предусмотрены библиотеки Python Matplotlib и Seaborn. Графики представляют состав выборки, последующие статусы, распределения исходных характеристик, сравнение моделей и диапазоны парных изменений ошибки, полученные повторным формированием выборок компаний и целых наборов УС. Подписи указывают анализируемую совокупность, единицы измерения и преобразования, необходимые для самостоятельного прочтения изображения.

2.6 Задачи

- 1 Рассмотреть исследования предикторов успеха стартапов и подходы к определению прогнозируемого результата.
- 2 Описать происхождение и временные ограничения данных, сформировать выборку для сопоставления характеристик и последующих статусов.
- 3 Провести разведочный анализ, оценить полноту признаков и особенности записей с неизвестным последующим состоянием.
- 4 Сравнить простые и многомерные прогнозные модели, оценить дополнительную информативность сведений о команде, географии и деятельности компаний.
- 5 Проверить чувствительность результатов к разбиению и составу совокупности; оценить добавление и исключение блоков, представить условные диапазоны изменений ошибки и интерпретацию частых тегов.
- 6 Визуализировать результаты и сформулировать выводы о возможностях прогнозирования по данным каталога и границах применимости этих выводов.

2.7 План работы

Первоначальный план проекта сохранён в приложении [A](#); он относится к прежней постановке исследования.

Таблица [2.1](#) содержит план переработки с 12 августа 2026 года до защиты 3 октября 2026 года. Срок сдачи отчётных документов, включая текст курсовой работы, — 18 сентября; презентация должна быть подготовлена и сдана до 1 октября включительно. Редактура текста ведётся параллельно с анализом, чтобы завершить проверку результатов до сдачи документов. План задаёт сроки задач, а не подтверждает их выполнение.

2.8 Использование генеративных моделей

При подготовке работы автор использовал OpenAI Codex при переработке постановки исследования, редактировании текста, написании и проверке программного кода, построении визуализаций и технической сборке документа. Предложения моделей проверялись по исходным данным, научным источникам, программному коду и результатам автоматических тестов; окончательные решения и ответственность за содержание работы принадлежат автору. Цели, способ и ограничения применения моделей приведены в разделе [9](#).

Таблица 2.1: План переработки и подготовки к защите (12.08.2026 – 03.10.2026)

Этап	Период	Основные задачи	Результат
1. Постановка исследования	12.08–18.08	Проверка литературы; уточнение показателя успеха, совокупности и периода наблюдения; редактura введения	Постановка и проверенные источники
2. Подготовка данных	19.08–25.08	Сопоставление компаний; разделение исходных признаков и поздних статусов; учёт пропусков и найденных записей	Аналитическая выборка и отчёт о преобразованиях
3. Обновление EDA	26.08–01.09	Пересчёт распределений последующих статусов; анализ пропусков и групп по году набора; обновление графиков	Графики и раздел EDA
4. Прогнозные модели	02.09–08.09	Фиксация схемы проверки и метрик; сравнение простых прогнозов, логистической регрессии и градиентного бустинга	Сравнение моделей без утечки данных
5. Предикторы и проверка чувствительности	09.09–14.09	Оценка вклада групп признаков, диапазонов парных изменений ошибки и качества вероятностей; сравнение результатов при разных способах разделения данных	Оценки дополнительной информативности признаков
6. Переработка текста	12.08–16.09 Параллельно	Обновление обзора, методов и результатов; согласование чисел и графиков; исправление неподтверждённых выводов	Полный текст курсовой работы
7. Итоговая проверка	15.09–17.09	Повторный запуск анализа; проверка ссылок и сборки LaTeX; подготовка комплекта отчётных документов	Проверенный комплект документов
8. Сдача документов	18.09	Сдача отчётных документов, включая текст курсовой работы	Документы сданы
9. Презентация	19.09–01.10	Подготовка слайдов и доклада по сданной работе; проверка соответствия результатов; сдача презентации до 01.10 включительно	Презентация сдана
10. Подготовка к выступлению	02.10	Репетиция доклада; подготовка ответов на вопросы о методах и ограничениях	Готовность к выступлению
11. Защита	03.10	Доклад и ответы на вопросы комиссии	Защита курсовой работы

3 Обзор литературы

Исследования результатов молодых компаний различаются прежде всего определением результата и составом наблюдаемой совокупности. Привлечение следующего раунда финансирования, прекращение деятельности, поглощение и выход на биржу фиксируют разные события. Их нельзя объединять под названием «успех» без указания того, какое именно событие наблюдается и в течение какого периода [1, 17, 13].

3.1 Определение результата

В работе [1] прослежена судьба 250 технологических компаний, основанных в Северной Калифорнии в 1960-е годы. К 1988 году 50% компаний прекратили деятельность, 32% были объединены с другими компаниями или поглощены, 18% продолжали самостоятельную работу. Такое разделение не сводит все исходы к противопоставлению «успеха» и «неудачи». Вместе с тем доли, полученные для компаний одного региона и периода, не характеризуют современные наборы Y Combinator.

В исследовании CapitalVX на данных Crunchbase прогнозируются поглощение или выход компании на биржу, прекращение деятельности и сохранение частного статуса; последующее финансирование рассматривается отдельно [13]. Поглощение и публичный статус здесь представляют наблюдаемые корпоративные события, а не непосредственную оценку прибыльности компании или доходности инвестиций. В частности, поглощение может происходить на разных финансовых условиях, которые статус компании не раскрывает.

В исследуемых данных исходом считается наличие у компании, активной 13 июля 2023 года, статуса поглощённой или публичной в августовской версии 2026 года. Отсутствие такого статуса не означает прекращения деятельности: отрицательный класс включает также компании, которые продолжают работать. Записи без установленного статуса в позднем срезе составляют отдельную группу и не приравниваются к отрицательным наблюдениям. Это разграничение определяет смысл как описательных сравнений, так и прогнозных оценок.

3.2 Характеристики компаний и прогнозный анализ

В работе [4] анализируются результаты опроса 885 венчурных инвесторов из 681 организации. При принятии инвестиционных решений респонденты придают команде большее значение, чем продукту или технологии. Однако ответы инвесторов описывают критерии их выбора, а не точность прогноза по данным каталога Y Combinator. Доступные в ката-

логе число основателей и размер команды не отражают опыт участников, распределение обязанностей и качество их взаимодействия. Поэтому результат опроса служит основанием включить сведения о команде в проверку, но не позволяет заранее ожидать от этих двух переменных улучшения прогноза.

В работе [18] подробно рассмотрено различие между объяснением наблюдаемой зависимости и прогнозированием новых наблюдений. Для оценки прогностической полезности недостаточно содержательно истолковать связь признака с исходом: необходимо установить, повышает ли он качество на данных, не участвовавших в обучении. Это относится и к сведениям о географии и сфере деятельности компании. Их вклад определяется сравнением моделей на одинаковых проверочных наблюдениях, в том числе относительно базового прогноза по году и сезону набора Y Combinator и возрасту.

3.3 Публичные сведения и текстовые признаки

В работе [17] прогнозируется получение раунда Series A или более позднего раунда в течение года после начального финансирования. Наряду со структурированными характеристиками используются сведения о сотрудниках и упоминания компаний в интернете. В Таблице 4 этой работы площадь под ROC-кривой полной модели равна 0,854; у варианта без подробных признаков доменов, упоминающих компанию, — 0,807. Различие получено для прогноза финансирования и определённого типа внешних сведений. Оно не устанавливает полезность описаний и тегов из карточек Y Combinator при прогнозировании поглощения или выхода на биржу.

В работах [7, 8] исследуются регистрационные сведения о 55 914 датских компаниях, основанных в 2012–2014 годах. Оцениваются разные исходы, включая прекращение деятельности, рост занятости, высокую рентабельность активов и показатели инновационной активности. Текстовые описания деятельности помогали прогнозировать инновационные показатели, тогда как высокая рентабельность активов оставалась плохо предсказуемой [7]. Следовательно, информативность одного источника данных зависит от выбранного исхода. Обязательные регистрационные сведения, кроме того, отличаются от добровольно заполненных карточек Y Combinator охватом и правилами формирования.

В обоих исследованиях текстовые признаки оценивались в сравнении с другими наборами сведений. Даже при обнаружении прогностической связи описание компании может отражать её деятельность или другие свойства, связанные с исходом. Из такой связи не следует, что изменение формулировки описания изменит перспективы компании.

3.4 Время наблюдения и проверка качества

В работе [17] задан годовой горизонт прогноза, а обучающие и проверочные наблюдения разделены по времени. В работе [7], напротив, 70% компаний случайным образом отведены для оценки моделей и 30% — для проверки; признаки, рассчитываемые с использованием исходов компаний, формируются на обучающей части. Случайное разбиение позволяет оценить качество внутри изучаемой совокупности, но само по себе не проверяет прогноз на новом календарном периоде. Поэтому оценки из этих работ нельзя напрямую сопоставлять без учёта различий в исходах, горизонтах и схемах проверки.

Для компаний Y Combinator доступны характеристики на 13 июля 2023 года и статусы в августовской версии 2026 года. Два среза позволяют установить состояние на конечную дату, но не точный момент поглощения, выхода на биржу или прекращения деятельности. Разделение проверочных данных по наборам Y Combinator показывает, сохраняется ли направление различий при полном исключении отдельных наборов из обучения. Оно не воспроизводит прогнозирование на последовательности будущих календарных периодов.

В работе [9] утечка информации названа одной из причин завышенных оценок качества моделей. В рассматриваемой постановке исходные признаки должны относиться к июлю 2023 года, а параметры преобразований и моделей — оцениваться без использования проверочных наблюдений. Отдельное ограничение связано с компаниями, для которых статус на август 2026 года установить не удалось: их исключение из прогноза с известным исходом может изменить состав оцениваемой выборки. Ни учёт года набора, ни корректное разделение данных при обучении не устраняют это ограничение.

В отличие от работ о последующем финансировании, здесь оценивается конечный статус исходно активных компаний Y Combinator. Проверяется, улучшают ли характеристики, известные в июле 2023 года, прогноз поглощения или публичного статуса к августу 2026 года по сравнению с годом и сезоном набора и возрастом. Модели сравниваются на одинаковых проверочных компаниях; отдельно приводится разброс парных изменений ошибки при повторном формировании выборок компаний и целых наборов YC. Записи с неизвестным исходом не получают искусственной отрицательной метки. Даже повторяющееся на разных разбиениях улучшение прогноза не свидетельствовало бы о причинном влиянии выявленных характеристик на судьбу компании [18].

4 Описание данных

4.1 Источники и даты наблюдения

Для исследования использованы три выгрузки каталога компаний Y Combinator с платформы Kaggle [6, 5]. Файлы за февраль и июль 2023 года имеют одинаковые поля. Поздний файл относится к августовской версии 2026 года; в программе для неё используется обозначение 01.08.2026. Состав файлов и их роль приведены в Таблице 4.1. Обозначение версии не означает, что каждое поле карточки было обновлено в день выпуска версии.

Таблица 4.1: Исходные файлы и их роль в исследовании. Число строк указано до удаления точных повторов, число компаний рассчитано по уникальным идентификаторам.

Дата / версия	Строк	Компаний	Полей	Использование
27.02.2023	4 128	4 128	16	Проверка согласованности с июльским файлом
13.07.2023	8 410	4 297	16	Определение исходной группы и её характеристик
01.08.2026	6 110	6 110	23	Определение последующего статуса

Февральскому срезу соответствует файл `2023-02-27-yc-companies.csv`, июльскому — `2023-07-13-yc-companies.csv`. Поздняя версия представлена файлом `yc_companies.csv`.

Автор исследования скачал поздний файл со страницы Kaggle в середине августа 2026 года. Согласно его сведениям о странице источника, датасет обновляется ежемесячно первого числа. Поэтому 01.08.2026 принято как обозначение августовской версии, а не как подтверждённый момент сбора каждой строки. Номер версии Kaggle и точный день скачивания не сохранены. Утверждения о позднем состоянии относятся к содержимому этого файла; точный горизонт до календарного дня не устанавливается. Основание датировки записано в `data/source_provenance.json`.

Сведения получены из сторонних выгрузок, а не собраны непосредственно с сайта Y Combinator. Контрольные суммы по алгоритму SHA-256 рассчитываются в функции `main` файла `src/data_preprocessing.py` и записываются в локальный отчёт `artifacts/preprocessed/cohort_report.json`. Контрольная сумма подтверждает идентичность файла, но не дату сбора. Полученные значения приведены в Таблице 4.2.

Таблица 4.2: Контрольные суммы исходных файлов по алгоритму SHA-256

Файл	Контрольная сумма
2023-02-27-yc-companies.csv	ba602c1e186a6aa2407ed75f3081536e48519c8b6ed8f065e7a8273dc1cbe37c
2023-07-13-yc-companies.csv	766d367b69cba93e370a868b3d62d5bdacf1dad1ba865085fd78cfa72241d942
yc-companies.csv	c9336c008895c6f2bd6e53a47ce71ac509fe8fbb0bd72adde276dce05ed89ccc

4.2 Поля исходных файлов

Структура файлов 2023 года приведена в Таблице 4.3, структура позднего файла — в Таблице 4.4. Если поле принимает произвольный текст или большое число различных категорий, в Таблицах указаны формат и несколько примеров; конечные наборы статусов и логических значений перечислены полностью. Пустые ячейки означают отсутствие сведений в источнике. Там, где поздняя выгрузка не содержит словаря полей, их описание ограничено названием и форматом записанных значений.

Таблица 4.3: Поля февральской и июльской выгрузок 2023 года. Названия и примеры значений сохранены в форме исходных файлов.

Поле	Возможные значения	Содержание
<code>company_id</code>	Положительное целое число	Идентификатор компании в каталоге; служит ключом при сопоставлении выгрузок.
<code>company_name</code>	Текст, например <code>moonrepo</code>	Название компании; совпадение названий не заменяет совпадения идентификаторов.
<code>short_description</code>	Короткий текст либо пропуск	Однострочное описание деятельности компании.
<code>long_description</code>	Текст либо пропуск	Развёрнутое описание деятельности, если оно заполнено в карточке.
<code>batch</code>	Код набора, например <code>W23</code> , <code>S22</code> или <code>IK12</code>	Обозначение набора Y Combinator. Буквы <code>W</code> и <code>S</code> обозначают зимний и летний наборы; <code>IK12</code> не имеет стандартного сезонного обозначения.
<code>status</code>	<code>Active</code> , <code>Inactive</code> , <code>Acquired</code> , <code>Public</code>	Статус компании на дату соответствующей выгрузки.
<code>tags</code>	Список строк, например <code>['SaaS', 'B2B']</code> , либо пустой список	Тематические метки карточки. Одна компания может иметь несколько меток.
<code>location</code>	Текст, например <code>Portland, OR</code> , либо пропуск	Местоположение в исходной записи без выделения страны и города по единому правилу.
<code>country</code>	Краткий код страны, например <code>US</code> или <code>IN</code> , либо пропуск	Страна, выделенная в источнике в отдельное поле.
<code>year_founded</code>	Год основания либо пропуск	Указанный в карточке год основания; точная дата не содержится в этом поле.
<code>num_founders</code>	Целое число от 0 до 6	Число основателей в источнике. Ноль при подготовке считается неизвестным значением.
<code>founders_names</code>	Список имён, в том числе пустой	Имена основателей в строковом представлении списка.
<code>team_size</code>	Неотрицательное целое число либо пропуск	Численность команды по карточке компании; ноль сохраняется как отдельное наблюдаемое значение.
<code>website</code>	Ссылка на сайт либо пропуск	Адрес сайта компании.
<code>cb_url</code>	Ссылка на Crunchbase либо пропуск	Адрес карточки компании в каталоге Crunchbase.
<code>linkedin_url</code>	Ссылка на LinkedIn либо пропуск	Адрес страницы компании в LinkedIn.

В поздней выгрузке отсутствуют отдельные поля страны, года основания, числа и имён основателей. Эти сведения не восстанавливались по поздним адресам или другим по-

лям: признаки для анализа исходного состояния взяты из июльского файла.

Одноимённые по смыслу поля приведены к общей схеме: `company_id` раннего файла и `id` позднего получили название `id`. Поля `launched_at`, `industries`, `regions`, `app_video_public`, `demo_day_video_public`, `app_answers` и `question_answers` не вошли в очищенный поздний срез. Из него к исходным записям присоединён только статус; остальные поздние характеристики не использованы как признаки прогноза.

Таблица 4.4: Все поля выгрузки августовской версии 2026 года. Для перечислений с множеством значений приведены формат и примеры.

Поле	Возможные значения	Содержание
<code>id</code>	Положительное целое число	Идентификатор компании; сопоставляется с полем <code>company_id</code> ранней выгрузки.
<code>name</code>	Текст	Название компании в позднем каталоге.
<code>website</code>	Ссылка на сайт либо пропуск	Адрес сайта компании на дату поздней выгрузки.
<code>all_locations</code>	Перечень мест текстом либо пропуск	Все местоположения, указанные в карточке; несколько мест могут быть разделены точкой с запятой.
<code>long_description</code>	Текст либо пропуск	Развёрнутое описание компании в поздней карточке.
<code>one_liner</code>	Короткий текст либо пропуск	Однострочное описание компании; по смыслу соответствует раннему <code>short_description</code> .
<code>team_size</code>	Неотрицательное целое число либо пропуск	Численность команды в поздней карточке. Для исходных признаков это значение не используется.
<code>industry</code>	Девять категорий: B2B, Consumer, Education, Fintech, Government, Healthcare, Industrials, Real Estate and Construction, Unspecified	Широкая категория деятельности в классификации позднего источника.
<code>subindustry</code>	Категория, например B2B -> Infrastructure	Более подробное направление деятельности; в файле встречаются 59 обозначений.
<code>launched_at</code>	Дата и время, например 2011-11-23 10:52:03	Метка времени запуска, указанная источником. Она не приравнивается к году основания компании.
<code>tags</code>	Список строк либо пустой список	Тематические метки в поздней карточке. Они могут отличаться от меток 2023 года.
<code>top_company</code>	True, False либо пропуск	Отметка компании как одной из выделенных в каталоге.
<code>isHiring</code>	True или False	Признак открытого найма в поздней карточке.
<code>nonprofit</code>	True или False	Признак некоммерческой организации.
<code>batch</code>	Сезон и год, например Winter 2022; также Unspecified	Обозначение набора Y Combinator в формате позднего источника. В файле есть весенние и осенние наборы, а также одна запись с годом 2027.
<code>status</code>	Active, Inactive, Acquired, Public	Статус компании на дату поздней выгрузки; единственное содержательное поле, переносимое в исследуемую группу.

Продолжение Таблицы 4.4

Поле	Возможные значения	Содержание
<code>industries</code>	Список строк, например ['B2B', 'Infrastructure']	Перечень уровней отраслевой классификации в исходной карточке.
<code>regions</code>	Список строк, например ['Europe', 'Remote']	Географические и связанные с удалённой работой метки источника; это не отдельное поле страны.
<code>stage</code>	Early или Growth	Категория стадии развития в позднем каталоге.
<code>app_video_public</code>	True или False	Признак публичной доступности видеозаписи из заявки в Y Combinator.
<code>demo_day_video_public</code>	True или False	Признак публичной доступности видеозаписи выступления на презентационном дне.
<code>app_answers</code>	True, False либо пропуск	Признак, связанный с ответами из заявки. В 6 033 из 6 110 строк значение отсутствует; смысл пропуска источник не разъясняет.
<code>question_answers</code>	True или False	Признак публичной доступности ответов компании на вопросы в каталоге.

4.3 Формирование исследуемой группы и производные поля

Единица наблюдения — компания с уникальным идентификатором. Исходная группа состоит из 3 110 компаний со статусом **Active** в июльской выгрузке. Февральский файл использован для проверки согласованности записей, но не для заполнения июльских пропусков. Производные поля рассчитаны после удаления повторов и очистки исходных значений.

В Таблице 4.5 перечислены производные характеристики, технические поля и целевая переменная. Технические поля предназначены для учёта происхождения записей и сопоставления срезов; в прогноз они не включены.

Таблица 4.5: Производные и технические поля подготовленных данных. Расчёт характеристик компании выполняется отдельно внутри каждого среза; в прогноз поступают только характеристики июля 2023 года.

Поле	Возможные значения	Способ получения
<code>tags</code>	Список различных меток; возможен пустой список	Строковое представление разбирается в список; пробелы по краям меток удаляются, повторы исключаются.
<code>tag_count</code>	Неотрицательное целое число	Число различных меток после разбора <code>tags</code> ; пустому списку соответствует ноль.
<code>description_length</code>	Неотрицательное целое число либо пропуск	Число символов в очищенном кратком описании. При отсутствии описания длина остаётся неизвестной.
<code>company_age</code>	Неотрицательное число лет либо пропуск	Год среза минус <code>year_founded</code> . Это разность календарных лет, а не возраст в полных годах.
<code>batch_year</code>	Год набора либо пропуск	Год выделяется из <code>batch</code> . Если он позже года среза, числовое значение признаётся недопустимым.

Продолжение Таблицы 4.5

Поле	Возможные значения	Способ получения
<code>batch_season</code>	Winter, Summer, Spring, Fall либо пропуск	Сезон выделяется из стандартного кода набора. Для IK12 сезон не назначается.
<code>regular_batch</code>	True или False	Показывает, распознан ли обычный код с сезоном и годом. Для IK12 и нераспознанных обозначений значение ложно.
<code>future_batch</code>	True или False	Показывает, что извлечённый год набора позже года соответствующего среза. Исходный код при этом сохраняется, а <code>batch_year</code> становится пропуском.
<code>snapshot_date</code>	Дата соответствующей выгрузки	Постоянная дата, присвоенная всем строкам очищенного среза.
<code>source</code>	yc_2023_feb, yc_2023_jul или yc_2026	Обозначение файла-источника, присвоенное при загрузке.
<code>status_baseline</code>	active	Июльский статус после отбора исходной группы; исходное поле <code>status</code> переименовано.
<code>status_followup</code>	active, inactive, acquired, public, unknown	Статус сопоставленной компании из позднего файла. При отсутствии записи проставляется <code>unknown</code> .
<code>followup_found</code>	True или False	Результат сопоставления идентификатора с поздним файлом.
<code>outcome_known</code>	True или False	Показывает, входит ли поздний статус в четыре распознаваемые категории.
<code>success_binary</code>	1, 0 либо пропуск	Единица присваивается статусам <code>acquired</code> и <code>public</code> ; ноль — статусам <code>active</code> и <code>inactive</code> . При неизвестном статусе значение отсутствует.
<code>followup_date</code>	2026-08-01	Обозначение августовской версии; не дата обновления каждой карточки.

При очистке пустые строки заменены пропусками, статусы приведены к строчным буквам. Коды стран записаны заглавными буквами: USA и UNITED STATES заменены на US, UK и UNITED KINGDOM — на GB. Нулевое число основателей переведено в пропуск, нулевой размер команды сохранён. Отрицательные и дробные значения размера команды, числа основателей и года основания признаны недопустимыми. Год основания также переведён в пропуск, если он равен нулю или превышает год выгрузки.

В прогнозном эксперименте размер команды представлен как $\ln(1 + x)$, где x обозначает число человек. Неизвестный сезон выделен в отдельную категорию. При обучении логистической регрессии пропуски числовых признаков отмечены отдельными индикаторами, а год набора и возраст представлены сплайнами. Заполнение числовых пропусков и оценка параметров преобразования проводились только на обучающих частях. Подробности приведены в разделе 6.

4.4 Последующий статус и границы наблюдения

Исходные и поздние записи сопоставлены по уникальному идентификатору с сохранением всех компаний июльской группы. У 3 046 компаний поздний статус установлен; 64 компании в файле августовской версии 2026 года не найдены и сохранены с неизвестным исходом. Компании, присутствующие только в поздней выгрузке, в исследуемую группу не вошли.

Положительная метка присвоена поглощённым и публичным компаниям, отрицательная — активным и неактивным в августовской версии 2026 года. При неизвестном позднем статусе метка отсутствует. Отрицательный класс означает лишь отсутствие выбранного корпоративного события на конечную дату; финансовый результат компании и дата события по этим данным не определяются.

4.5 Проверки и воспроизводимость

Удалены только полностью совпадающие строки. Отсутствующий либо некорректный идентификатор и несовпадающие записи с одним идентификатором считались ошибками, препятствующими сопоставлению; в использованных файлах таких конфликтов после удаления повторов не обнаружено. Коду IK12 сезон не присвоен. При разборе полных обозначений наборов Spring отделён от Summer.

Сохранены очищенные срезы, исследуемая группа и машиночитаемый отчёт о подготовке. Отчёт фиксирует размеры и контрольные суммы файлов, пропуски, удалённые повторы, недопустимые числовые значения и результаты сопоставления. Для разведочного анализа использована сохранённая группа компаний; сводные Таблицы, лежащие в основе Рисунков, также записаны в отдельные файлы.

5 Разведочный анализ данных

Разведочный анализ выполнен для компаний Y Combinator, имевших активный статус 13 июля 2023 года. Исходные характеристики взяты из выгрузки на эту дату, последующие статусы — из выгрузки августовской версии 2026 года. Рассмотрены состав исследуемой группы, полнота записей и распределения характеристик. Источники данных опубликованы на Kaggle [6, 5].

5.1 Формирование исследуемой совокупности

В июльском файле из 8410 строк 4113 являются точными повторами. После их удаления остаются 4297 компаний с уникальными идентификаторами. На исходную дату 3110 из них были активны и вошли в исследуемую группу. Среди остальных 665 компаний были неактивны, 506 поглощены и 16 имели публичный статус. В поздней выгрузке найдены 3046 компаний исходной группы; 64 записи отсутствуют. Последним не присвоена отрицательная целевая метка, поскольку их статус в августовской версии 2026 года не установлен.

С февральской выгрузкой совпадают 4113 июльских идентификаторов. Только в феврале представлены 15 компаний, только в июле — 184. Среди общих записей изменились 68 статусов, 357 значений размера команды и 62 года основания. В подсчёте учтены также переходы между заполненным и пустым значением. По двум выгрузкам нельзя отделить изменение характеристики от исправления карточки. Февральские значения не использованы для заполнения июльских пропусков.

Исходная группа ограничена компаниями, представленными в каталоге и сохранившими активный статус к июлю 2023 года. Поэтому её характеристики не описывают все компании, когда-либо принятые в Y Combinator, и тем более все предпринимательские инициативы.


5.2 Полнота исходных характеристик

На Рисунке 5.1 приведены пропуски исходных характеристик. Год основания не указан у 356 компаний, что составляет 11,45% исследуемой группы. Подробное описание отсутствует у 206 компаний, страна — у 89, размер команды — у 47, краткое описание — у 43. Число основателей неизвестно у четырёх компаний после замены исходных нулей на пропуски.

Пустой список тегов имеют 145 компаний, или 4,66% группы. Для них число перечисленных меток равно нулю; сведения о деятельности компании могут при этом содержаться

Полнота исходных характеристик компаний

YC: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Сведения на 13.07.2023. Пустой список тегов означает отсутствие перечисленных тегов. Нулевое число основателей признано неизвестным; поздними значениями пропуски не заполнены.

Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.1: Пропуски характеристик среди 3 110 компаний Y Combinator, активных 13 июля 2023 года. Столбцы показывают число компаний без указанных сведений, подписи — долю исходной группы. Пустые списки тегов учтены отдельно; данные августовской версии 2026 года для заполнения пропусков не использованы.

в описании. Длина описания и количество тегов характеризуют заполнение карточки, а не качество продукта.

Размер команды, число основателей, возраст, страна и краткое описание одновременно известны у 2 632 компаний. Полное исключение строк с пропусками в этих пяти полях сократило бы исходную группу на 478 компаний, или 15,37%. В описательных расчётах пропуски исключались отдельно для каждого показателя; в прогнозном анализе заполнение числовых значений выполнялось внутри обучающих частей.


5.3 Последующие статусы и наблюдаемый показатель успеха

В августовской версии 2026 года активный статус сохранили 2 405 компаний исходной группы; 369 были неактивны, 265 поглощены, семь имели публичный статус. Распределение приведено на Рисунке 5.2. Для 64 компаний поздний статус неизвестен. Зафиксированные статусы не содержат даты перехода между состояниями.

Положительная целевая метка присвоена 272 компаниям, или 8,93% от 3 046 компаний с известным статусом. Остальные 2 774 компании образуют отрицательный класс: на конечную дату они были активны либо неактивны, но не поглощены и не публичны. Эта метка не

Статусы компаний к концу периода наблюдения

УС: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Показатель успеха: поглощение или публичный статус. Активные компании не исключены. Неизвестный статус не приравнивается к неактивности; статус каталога не задаёт точную дату события.
Источник: выгрузки каталога УС на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.2: Статусы в августовской версии 2026 года у 3 110 компаний Y Combinator, активных 13 июля 2023 года. Количество и доля каждой группы рассчитаны с учётом 64 компаний без известного позднего статуса. Положительная целевая метка объединяет поглощённые и публичные компании.

является общей оценкой экономического результата компании.

На поглощения приходятся 265 из 272 положительных исходов, или 97,43%. Поэтому качество прогноза объединённого показателя в основном отражает распознавание поглощённых компаний. Семь публичных компаний представлены слишком малой группой для самостоятельной оценки качества прогноза этого исхода.

При двух крайних вариантах статуса 64 ненайденных компаний доля положительного исхода среди всех 3 110 исходных компаний находится между $272/3\,110 = 8,75\%$ и $336/3\,110 = 10,80\%$. Эти границы отражают только неизвестные исходы и не учитывают возможные ошибки в записанных статусах.


Матрица переходов отдельно не строится. Все компании имели один исходный статус, поэтому её единственная содержательная строка совпала бы с распределением на Рисунке 5.2. Кроме того, срезы не содержат дат изменения статуса и промежуточных состояний. Сопоставление показывает состояние компаний в двух точках времени, но не позволяет оценить скорость, последовательность или момент переходов.

5.4 Годы набора и доступность последующих статусов

Компании сгруппированы по году поступления в Y Combinator. На Рисунке 5.3 сопоставлены численность групп и распределение поздних статусов внутри них. Ранние годы объединены, нестандартный код IK12 выделен отдельно.

Годы набора и последующие статусы исходной когорты

YC: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Группы заданы по году набора; малочисленные ранние годы объединены. IK12 показан отдельно от стандартных сезонных наборов. На правой панели знаменатель — все компании группы, включая неизвестные статусы. Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.3: Численность и поздние статусы компаний Y Combinator по годам набора. Показаны 3 110 компаний, активных 13 июля 2023 года; статусы взяты из августовской версии 2026 года. Слева указано число компаний, справа — доли статусов внутри каждой группы, в том числе неизвестных. Ранние годы объединены; IK12 оставлен отдельной группой.

К наборам 2021–2023 годов относятся 1 680 компаний, или 54,02% исходной группы. На 2018–2020 годы приходятся 845 компаний, на 2015–2017 годы — 357, на стандартные наборы 2006–2014 годов — 184. Ещё 44 компании имеют код IK12. Распределение отражает состав действующих компаний на июль 2023 года, а не число всех когда-либо принятых компаний: более ранние участники, утратившие активный статус до этой даты, отсутствуют.

Поздняя выгрузка не содержит 43 из 44 компаний группы IK12; доля найденных записей в ней составляет 97,73%. Эта группа даёт 67,19% всех неизвестных исходов. Среди остальных 3 066 компаний не найдена 21, или 0,68%. Следовательно, общая доля сопоставления 97,94% скрывает сильную неоднородность по обозначению набора. Причина почти полного отсутствия IK12 в позднем источнике по имеющимся данным не установлена.

У компаний с неизвестным поздним статусом чаще отсутствует год основания: 31 из 64 записей, или 48,44%. Среди компаний с известным статусом этот показатель равен 325 из 3 046, или 10,67%. Поэтому выборка с известным исходом отличается от полной исходной

группы не только доступностью целевой метки, но и полнотой характеристик.

Интервал между двумя срезами одинаков для всех компаний, но группы по году набора различаются возрастом и временем, прошедшим после поступления в акселератор. Наблюдаемые различия статусов не отделяют влияние года набора от этих характеристик.

5.5 Распределения числовых характеристик

На Рисунке 5.4 представлены размер команды, число основателей и приближённый возраст на июль 2023 года. Возраст рассчитан как разность календарных лет между исходным срезом и основанием компании.



Рисунок 5.4: Распределения характеристик компаний Y Combinator, активных 13 июля 2023 года. Размер команды известен у 3 063 компаний, число основателей — у 3 106, приближённый возраст — у 2 754. По вертикали показано число компаний. Для размера команды применена шкала $\ln(1 + x)$ с подписями в количестве человек; столбцы показывают число компаний в интервалах, а не плотность.

Медианный размер команды составляет девять человек, первый и третий квартили — три и 25 человек. Среднее равно 55,59, максимум — 7 000. У 90% компаний с заполненным полем команда насчитывает не более 80 человек. Из-за редких больших значений среднее заметно превышает медиану. Логарифмическая шкала позволяет показать небольшие команды без удаления 11 нулевых наблюдений и крайних значений; достоверность отдельных крупных значений по одному распределению не установлена.

Два основателя указаны у 1 725 компаний, или 55,54% записей с известным числом основателей. Один основатель указан у 692 компаний, три — у 575. От четырёх до шести основателей имеют в сумме 114 компаний.


Медианный приближённый возраст равен трём календарным годам, первый и третий квартили — двум и пяти годам; наблюдаемый диапазон составляет от нуля до 18 лет. Это возраст компаний, остававшихся активными на июль 2023 года, а не распределение срока существования всех компаний акселератора.

5.6 Исходный размер команды в группах последующего статуса

На Рисунке 5.5 исходный размер команды сопоставлен с поздним статусом компании. Скрипичные диаграммы показывают распределение значений на логарифмической шкале; коробки и усы рассчитаны по исходному числу сотрудников. Чтобы редкие очень крупные команды не растягивали оценку плотности, значения выше 99-го перцентиля в каждой группе показаны точками отдельно. При оценке квартилей эти значения сохранены.

Исходный размер команды и последующий статус компании

УС: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Группы заданы статусом в августовской версии 2026. Скрипки: плотность на логарифмической шкале без значений выше 99-го перцентиля каждой группы; ширина нормирована отдельно. Эти значения показаны точками. Коробки и усы рассчитаны по всем данным до преобразования шкалы. Семь публичных компаний показаны точками без оценки плотности. Источник: выгрузки каталога УС на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.5: Размер команды на 13 июля 2023 года по статусу компании в августовской версии 2026 года. Рассмотрены компании Y Combinator, активные на исходную дату; у каждой группы указано число записей с известным размером команды. Ширина скрипки показывает плотность на шкале $\ln(1 + x)$ и нормирована отдельно для каждой группы. Значения выше 99-го перцентиля исключены только из оценки плотности и показаны точками. Коробки и усы рассчитаны по всем исходным значениям: черта показывает медиану, коробка — межквартильный интервал, усы — крайние значения в пределах полутора межквартильных размахов. Семь публичных компаний показаны точками без оценки плотности. Подписи горизонтальной оси даны в количестве человек.

У компаний, сохранивших активный статус, медианный исходный размер команды равен десяти человек; у ставших неактивными — пяти, у поглощённых — восьми. Межквар-

тельные интервалы составляют соответственно 4–30, 2–10 и 4–22,5 человека. Скрипичные диаграммы показывают концентрацию небольших команд во всех трёх группах и существенное перекрытие распределений. Поглощённые компании не выделяются более крупными исходными командами по сравнению с продолжающими работать.

В группе ставших неактивными у 76,0% компаний с известным размером команды было не более десяти сотрудников. Среди сохранивших активный статус эта доля составляет 52,7%, среди поглощённых — 58,9%. Обратная картина наблюдается в правой части распределения: команды численностью свыше 50 человек имели 3,9% ставших неактивными компаний, 16,4% сохранивших активный статус и 13,3% поглощённых. Показатели рассчитываются функцией `boxplot` файла [src/eda_analysis.py](#) и сохраняются в поле `team_by_status` отчёта `eda_summary.json`. Таким образом, различия касаются не только медианы, но и доли крупных команд; сами по себе они не устанавливают влияния размера команды на последующий статус.

У семи компаний с последующим публичным статусом медианный размер команды на исходную дату равен 1050 человек, межквартильный интервал — 175–2425. Эта малочисленная группа отличается по масштабу от остальных и делает положительный класс неоднородным. Различия на Рисунке не учитывают возраст и направление деятельности компаний.

5.7 Зависимости между исходными числовыми признаками

Матрица на Рисунке 5.6 содержит ранговые корреляции Спирмена между пятью исходными характеристиками. Коэффициент отражает согласованность порядка значений, а не линейное изменение одного признака при изменении другого. Каждая оценка рассчитана по компаниям с двумя известными значениями; число таких компаний указано в клетке.

Наибольшая по модулю корреляция наблюдается между возрастом и размером команды: $\rho_S = 0,58$ по 2716 компаниям. Более старшим компаниям чаще соответствует большая численность команды. Признаки связаны, но не взаимозаменяемы; сравнение команд между группами позднего статуса без учёта возраста может смешивать эти различия.

Корреляция возраста с числом тегов равна $\rho_S = -0,33$, размера команды с числом основателей — $\rho_S = 0,12$. Отрицательная связь возраста с числом тегов может отражать различия в заполнении карточек компаний разных лет; установить её причину по матрице нельзя.

Для каждой пары признаков из расчёта исключены только компании, у которых от-

Ранговые связи между исходными числовыми признаками

YC: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.

Размер команды	+1,00 n=3063	+0,12 n=3059	+0,58 n=2716	-0,14 n=3063	+0,15 n=3022
Число основателей	+0,12 n=3059	+1,00 n=3106	-0,07 n=2752	+0,08 n=3106	-0,02 n=3064
Возраст компании	+0,58 n=2716	-0,07 n=2752	+1,00 n=2754	-0,33 n=2754	+0,19 n=2742
Число тегов	-0,14 n=3063	+0,08 n=3106	-0,33 n=2754	+1,00 n=3110	-0,07 n=3067
Длина краткого описания	+0,15 n=3022	-0,02 n=3064	+0,19 n=2742	-0,07 n=3067	+1,00 n=3067
	Размер команды	Число основателей	Возраст компании	Число тегов	Длина краткого описания

Коэффициент Спирмена, расчёт по попарно полным наблюдениям; n — число пар. Насыщенность синего показывает модуль, знак указан числом. Возраст = 2023 — год основания; длина описания — число символов. Целевая переменная не включена. Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.6: Ранговые корреляции Спирмена между характеристиками 3 110 компаний Y Combinator, активных 13 июля 2023 года. В каждой клетке указаны коэффициент и число компаний с обоими известными значениями. Насыщенность цвета соответствует модулю коэффициента, направление связи показывает его знак. Возраст рассчитан по разности календарных лет, длина описания измерена в символах; поздний статус в матрицу не включён.

существует хотя бы одно из двух значений. Поэтому число наблюдений различается между клетками и указано непосредственно под соответствующим коэффициентом. Расчёт выполняется функцией `correlation_plot` в файле [src/eda_analysis.py](#); числовые результаты сохраняются в файлах `spearman.csv` и `spearman_pair_counts.csv`. Матрица характеризует парные монотонные связи между признаками; она не показывает их дополнительный вклад в прогноз позднего статуса.


Целевая метка намеренно не включена в матрицу. Коэффициент между отдельным признаком и бинарным исходом показал бы только нескорректированную парную связь на всей выборке. Он не учитывал бы совместное действие признаков и не оценивал бы переносимость на не использованные при расчёте данные. Прогностическая полезность блоков характеристик проверяется на внешних разбиениях в разделе 7.

5.8 Географический состав

Географический состав исходной группы представлен на Рисунке 5.7. Для сравнения США со странами, имеющими несколько десятков наблюдений, использована логарифмическая шкала числа компаний.

Десять наиболее представленных стран исходной когорты

УС: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Страна из исходного среза, без восстановления по поздним сведениям. Проценты от всех 3 110 компаний. Страна не указана у 89; остальные страны вне первой десятки не показаны.

Источник: выгрузки каталога УС на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.7: Десять наиболее представленных стран среди 3 110 компаний Y Combinator, активных 13 июля 2023 года. Положение точки показывает число компаний на логарифмической шкале, подпись — количество и долю всей исходной группы. Страна взята из июльской выгрузки; у 89 компаний она отсутствует. Остальные страны на Рисунке не показаны.

США указаны у 2 024 компаний, или 65,08% исходной группы. Индия представлена 181 компанией, Канада — 112, Великобритания — 105. У следующих шести стран на Рисунке от 34 до 78 компаний. За пределами первой десятки находятся ещё 325 компаний; у 89 страна неизвестна. Доли рассчитаны по всем 3 110 исходным компаниям, а не только по показанным странам.

На США приходится около двух третей исходной группы. Для большинства других стран число компаний невелико, а число положительных исходов ещё меньше. Показанное распределение характеризует присутствие стран в выборке, но не частоту поглощений или публичных статусов внутри них.

5.9 Тематические теги исходных карточек

На Рисунке 5.8 показаны метки, перечисленные в июльских карточках компаний. Отраслевая классификация поздней выгрузки в исходные признаки не включена. Одна компания учитывается не более одного раза для каждого тега, но может присутствовать в нескольких строках Рисунка.


Чаще всего встречается метка **SaaS**, обозначающая программное обеспечение как услугу: её имеют 819 компаний, или 26,33% группы. Метка **B2B** для решений, адресованных организациям, указана у 710 компаний, метка **Fintech** для финансовых технологий — у 559, инструменты для разработчиков — у 338. Эти обозначения описывают разные стороны деятельности и не образуют взаимоисключающую отраслевую классификацию.

Несколько меток относятся к искусственному интеллекту: *Artificial Intelligence* встречается у 269 компаний, **AI** — у 130, *Generative AI* — у 114; метка машинного обучения указана у 173 компаний. Эти группы могут пересекаться, поэтому сумма чисел не показывает количество компаний, работающих с искусственным интеллектом. Исходные обозначения на Рисунке не объединены.

В прогнозном эксперименте исходные тематические метки кодируются отдельно без объединения в смысловые группы. Словарь формируется только по обучающей части каждого разбиения.

Пятнадцать наиболее частых тегов деятельности компаний

YC: 3 110 компаний, активных 13.07.2023. Статусы: августовская версия 2026.



Теги на 13.07.2023: одна компания может иметь несколько тегов; сумма долей не обязана равняться 100%. Пустые списки: 145. AI и Artificial Intelligence сохранены как разные исходные теги; это не классификация отраслей.
Источник: выгрузки каталога YC на Kaggle; расчёты по исходному срезу и сопоставление по id.

Рисунок 5.8: Пятнадцать наиболее частых меток у 3 110 компаний Y Combinator, активных 13 июля 2023 года. Показаны число компаний с каждой меткой и доля всей исходной группы. Одна компания может иметь несколько меток, поэтому доли не суммируются до 100%. Обозначения AI и Artificial Intelligence сохранены отдельно; у 145 компаний список меток пуст.

6 Методология прогнозного анализа

6.1 Прогнозируемый исход

Прогнозный анализ проверяет, содержат ли характеристики компаний на 13 июля 2023 года информацию о поглощении или публичном статусе в августовской версии каталога 2026 года. Рассматриваются 3 046 исходно активных компаний с известным последующим статусом: 272 положительных и 2 774 отрицательных исхода. Ещё 64 компании с неизвестным статусом не получают искусственных меток. Датировка поздней версии и её ограничения описаны в разделе 4.

Целевая метка не противопоставляет экономически успешные и неуспешные компании. Активная частная компания может быть прибыльной, а поглощение не раскрывает условий сделки. Модели оценивают вероятность статуса в поздней выгрузке. Отбор по известному исходу ограничивает перенос результатов на полную исходную группу.

6.2 Блоки признаков и модели

Постоянный прогноз назначает каждой проверяемой компании долю положительных исходов в обучающей части. Базовая логистическая модель использует год и сезон набора УС вместе с возрастом компании. К ней добавляются размер команды и число основателей. Следующие варианты добавляют к этой расширенной основе страну, тематические теги или краткое описание. Полная модель объединяет все блоки. Отдельно обучаются четыре варианта полной модели с исключением команды, страны, тегов или описания. Во всех сравнениях используются одинаковые внешние разбиения; регуляризация каждого варианта подбирается заново во внутреннем цикле. Поэтому оценивается вклад блока в выбранную процедуру обучения, а не эффект механического обнуления коэффициентов.

Логистическая регрессия задаёт вероятность

$$\hat{p}(x) = \frac{1}{1 + \exp\{-\eta(x)\}}, \quad \eta(x) = \beta_0 + \beta^\top z(x),$$

где $z(x)$ — преобразованные признаки, β_0 — свободный член, β — коэффициенты. Год набора и возраст представлены кубическими сплайнами с четырьмя равномерно расположенными узлами на обучающем диапазоне. Размер команды заменяется на $\ln(1+x)$. Числовые пропуски заполняются медианами и отмечаются индикаторами; параметры заполнения, сплайнов и масштабирования оцениваются только внутри обучающих частей.

Сезон и страна кодируются бинарными столбцами; страны с частотой менее десяти объединяются по обучающей части. Каждый тег сохраняется целиком, включая пробелы и знаки пунктуации; словарь содержит метки, встретившиеся минимум у пяти обучающих компаний. AI и Artificial Intelligence не объединяются. Краткое описание преобразуется методом TF-IDF по словам и парам соседних слов, с удалением английских служебных слов, минимальной частотой пять документов и пределом 5 000 единиц. Проверочные данные не участвуют в построении словарей.

Для логистической регрессии применяется квадратичный штраф с $C \in \{0,1; 1; 10\}$. Дополнительная модель CatBoost использует год и сезон набора, возраст и характеристики команды [12]. Проверяются глубины 3 и 5, число итераций 200 и 500; скорость обучения равна 0,03, коэффициент регуляризации листьев — 5. CatBoost сравнивается прежде всего с логистической моделью на тех же признаках.

6.3 Учёт дисбаланса классов

Основные модели обучаются без изменения частот классов и настраиваются по логарифмической потере. Общая доля верных классов не используется: при положительном классе 8,93% она малоинформативна.

Для проверки весов классов создаются два дополнительных варианта полной логистической модели: без весов и с весами $w_c = n/(2n_c)$. Оба варианта подбираются по одному критерию — средней точности (AP), усреднённой по внутренним частям с весами по их размеру. Таким образом, сравнение не смешивает изменение весов с изменением критерия настройки. Выход взвешенной модели не считается калиброванной вероятностью; её LogLoss не используется для выбора основного вероятностного прогноза.

6.4 Схема проверки

Используется вложенная перекрёстная проверка: пять внешних и три внутренних части [15]. Термин «внешняя часть» означает внешний цикл внутри данной совокупности, а не независимую внешнюю валидацию. Все оцениваемые преобразования повторяются внутри обучающих частей [9].

Основная схема сохраняет целиком компании одного набора YC как во внешнем, так и во внутреннем цикле. Для каждого разбиения генерируются 128 вариантов: наборы обходятся в случайном порядке и целиком назначаются в часть, минимизирующую приращение суммы квадратов нормированных численностей компаний и положительных исходов.

Из допустимых вариантов с обоими классами в каждой части выбирается наиболее сбалансированный. Выбор опирается только на состав частей, без обучения моделей и оценки их качества.

Выполняются пять групповых и пять случайных стратифицированных повторов с начальными значениями генератора 42, 137, 271, 509 и 887. Разнообразие групповых разбиений проверяется скорректированным индексом Рэнда (ARI), инвариантным к перенумерации частей: единица означает одинаковое разбиение. Сохраняются идентификаторы компаний во всех внешних и внутренних частях. Повторы используют одну и ту же совокупность и не являются независимыми экспериментами. Групповая схема проверяет перенос между наборами, но не прогноз на будущем календарном периоде.

6.5 Метрики качества

Основной критерий вероятностных моделей — средняя логарифмическая потеря:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)].$$

Дополнительно рассчитываются ошибка Брайера, ROC-AUC и AP. Последняя равна сумме точности, взвешенной приращениями полноты [14]. Ориентир AP для неинформативного прогноза — частота положительного класса. Эти метрики сначала вычисляются отдельно в каждой части, затем усредняются с весами по её размеру; результаты повторов усредняются поровну. Во внутренней настройке применяется такое же правило. Прогнозы разных моделей не объединяются для расчёта AP и ROC-AUC.

Для PR-графика кривая каждой части переносится на общую сетку полноты ступенчатой интерполяцией; в интервале используется точность в его правой границе. Кривые усредняются с весами по размеру частей. AP в легенде рассчитана отдельно по исходным кривым и не является площадью под нарисованной усреднённой кривой.

В каждой внешней части отбираются $k_f = \lceil 0,1n_f \rceil$ компаний с наибольшими оценками. При совпадении оценок на границе используется ожидаемое число положительных исходов при случайном выборе среди связанных наблюдений. Внутри повтора суммируются числа отобранных компаний $K = \sum_f k_f$ и найденных положительных исходов $TP = \sum_f TP_f$:

$$P@10\% = \frac{TP}{K}, \quad R@10\% = \frac{TP}{N_+}, \quad Lift@10\% = \frac{P@10\%}{N_+/N}.$$

Здесь N_+ и N относятся ко всей проверяемой совокупности. Затем показатели усредняются

по повторам. Из-за округления отбирается немного больше 10% компаний. Эти метрики описывают ранжирование при ограниченном объёме отбора; практическая ценность зависит от стоимости и последствий решений.

Диаграмма надёжности сопоставляет средние вероятности с частотами в пяти квантильных группах проверочных прогнозов первого группового повтора [11]. Это описательная проверка, не доказательство калибровки на новых данных; дополнительная калибровка не выполняется.

6.6 Сравнение признаков и неопределённость

Вклад блока оценивается парной разностью индивидуальных потерь на одних и тех же компаниях. Положительное значение означает преимущество более полной модели. Рассматриваются добавления к базовой модели, исключения из полной, полная модель против постоянного прогноза и против более простой модели с тегами.

Сначала разности усредняются для каждой компании по пяти повторам. Затем строятся два условных 95%-ных диапазона из 2000 повторных выборок: отдельных компаний и целых наборов УС. При выборке наборов все компании выбранного набора сохраняются вместе, включая кратность его выбора; сумма потерь делится на общее число выбранных компаний. Тем самым сохраняется оценка среднего на компанию, а не на набор. Дополнительно сохраняются разности отдельно по повторам и наборам.

Оба диапазона условны относительно уже полученных прогнозов: модели не переобучаются. Выборка наборов учитывает совместное варьирование компаний внутри набора, но не всю неопределённость обучения и выбора модели. Границы не используются как формальные тесты значимости; сравнения нескольких блоков носят разведочный характер. Размах по повторам также не является доверительным интервалом.

6.7 Интерпретация и проверки чувствительности

Для двенадцати самых частых тегов в совокупности с известным исходом приводятся численность, число положительных исходов, медиана коэффициента и его 10–90%-ный диапазон по 25 внешним групповым обучающим частям модели с тегами. Метки выбираются по частоте без использования исхода. Доля положительных коэффициентов характеризует стабильность знака; диапазон коэффициентов не является доверительным интервалом, поскольку обучающие части пересекаются. Коэффициенты зависят от регуляризации и других тегов; они не устанавливают причинных эффектов или индивидуального прироста провероч-

ного качества.

SHAP для CatBoost рассчитывается на проверочных компаниях первого группового повтора [2]. Средний модуль вклада в логарифм шансов объясняет поведение этой модели, но не направление связи и не прирост качества [16].

Два дополнительных эксперимента полностью повторяют вложенное обучение шести моделей (постоянной, базовой, с командой, с тегами, полной и CatBoost) на пяти групповых повторах: без IK12 и без семи публичных компаний. Во втором случае положительным исходом остаётся поглощение, а исследуемая совокупность условна на отсутствие публичного статуса. Эти проверки характеризуют чувствительность результатов; они не восстанавливают неизвестные исходы и не заменяют независимую валидацию. Выбор вариантов исследования уточнялся после изучения данных, поэтому весь эксперимент остаётся разведочным.

7 Прогностическая полезность характеристик компаний

Результаты относятся к 3 046 компаниям с известным статусом в августовской версии 2026 года. Положительный класс включает 272 поглощённые или публичные компании. Основные оценки получены на пяти повторах вложенной проверки с разделением по полному коду набора УС. Настройка выполнялась без использования внешних проверочных компаний.

Адрес репозитория исследования на GitHub: https://github.com/Kiraashado/course_work_startup_success_predictors. Инструкции по запуску анализа приведены в README.md проекта. Для воспроизведения результатов необходимы исходные выгрузки с контрольными суммами из Таблицы 4.2 и версии зависимостей, зафиксированные в requirements-modeling.txt.

7.1 Качество вероятностного прогноза

Постоянный прогноз имеет LogLoss 0,3011, базовая модель по набору и возрасту — 0,3016, модель с добавлением команды — 0,3019. Для модели с тегами LogLoss равна 0,2968, для полной — 0,2958. Относительное снижение потери полной модели против постоянного прогноза составляет 1,75%. Сравнение относится к конкретным алгоритмам, преобразованиям и сеткам параметров.


Таблица 7.1: Качество проверочных прогнозов: среднее пяти групповых повторов. Для LogLoss и ошибки Брайера меньшее значение лучше, для AP и ROC-AUC — большее.

Модель	LogLoss	AP	ROC-AUC	Брайер
Постоянный прогноз	0,3011	0,0893	0,5000	0,0813
ЛР: набор и возраст	0,3016	0,1018	0,5353	0,0816
ЛР: набор, возраст и команда	0,3019	0,1017	0,5220	0,0816
ЛР: команда и география	0,3013	0,1087	0,5549	0,0815
ЛР: команда и теги	0,2968	0,1353	0,6052	0,0808
ЛР: команда и краткое описание	0,3014	0,1037	0,5396	0,0816
ЛР: все блоки признаков	0,2958	0,1402	0,6154	0,0806
CatBoost: набор, возраст и команда	0,3004	0,1109	0,5286	0,0813

ROC-AUC полной модели равна 0,6154, AP — 0,1402 при частоте положительного класса 0,0893. Эти показатели характеризуют ограниченное разделение классов. Небольшое улучшение среднего вероятностного прогноза не устанавливает практической полезности при принятии решений.

Ошибка вероятностного прогноза при двух схемах проверки

YC: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.



Все прогнозы получены во внешних проверочных частях; словари тегов и текста также оценивались только на обучающих данных. Разделение по наборам проверяет переносимость между группами, не между календарными периодами.

Источник: расчёты автора по выгрузкам YC с Kaggle.

Рисунок 7.1: LogLoss при случайном разделении и разделении целых наборов YC. Каждая точка — среднее пяти повторов соответствующей схемы.

7.2 Разнообразие разбиений и разброс результатов

Попарный ARI внешних групповых разбиений находится между 0,257 и 0,430. Таким образом, повторы существенно различаются и не сводятся к перестановке названий частей. Размах метрик между повторами приведён в Таблице 7.2. Он характеризует чувствительность к разбиению данной совокупности, но не неопределённость переноса на новый календарный период.

Таблица 7.2: Среднее и диапазоны результатов пяти повторов каждой схемы. Диапазоны — минимальное и максимальное значения, не доверительные интервалы.

Схема	Модель	LogLoss	Размах LogLoss	Размах AUC
По наборам	Постоянный прогноз	0,3011	[0,3010; 0,3012]	[0,5000; 0,5000]
По наборам	ЛР: команда и теги	0,2968	[0,2958; 0,2990]	[0,5883; 0,6108]
По наборам	ЛР: все блоки признаков	0,2958	[0,2948; 0,2985]	[0,5956; 0,6216]
Случайное	Постоянный прогноз	0,3009	[0,3009; 0,3009]	[0,5000; 0,5000]
Случайное	ЛР: команда и теги	0,2953	[0,2943; 0,2963]	[0,5996; 0,6196]
Случайное	ЛР: все блоки признаков	0,2944	[0,2932; 0,2953]	[0,6099; 0,6277]

Схемы проверяют разные условия обобщения: случайное разделение допускает присутствие компаний одного набора в обеих частях, групповое исключает это. Различие их средних показателей описывает чувствительность к схеме проверки; само по себе оно не доказывает величину систематического завышения качества случайной проверкой.

7.3 Добавление и исключение блоков признаков

Добавление тегов к модели с набором, возрастом и командой уменьшает LogLoss в среднем на 0,00510. Условные границы при повторной выборке целых наборов составляют [0,00163; 0,00808]. Для полной модели против постоянного прогноза изменение равно 0,00525 с границами [0,00130; 0,00954].

Исключения из полной модели представлены отдельно в Таблице 7.4. Они оценивают дополнительную информацию блока при наличии остальных сведений. Отсутствие улучшения в таком сравнении не означает отсутствия связи признаков с исходом вообще: результат зависит от остальных признаков, класса модели и регуляризации.

Разница полной модели и более простой модели с тегами равна 0,00099, условные границы по наборам — [-0,00008; 0,00197]. Это сравнение необходимо для оценки оправданности добавления страны и текста. Минимальная средняя ошибка сама по себе не устанавливает устойчивого преимущества более сложного варианта.

Улучшение от тегов наблюдается в 19 из 36 наборов, а не обязательно в каждом из них. Рисунок 7.3 показывает неоднородность результата. Малочисленные наборы имеют особенно

Таблица 7.3: Парные изменения LogLoss. Для добавлений положительное значение означает улучшение; для исключений — преимущество полной модели над моделью без блока. Две пары границ получены из 2 000 выборок компаний и целых наборов при фиксированных прогнозах.


Сравнение	ΔL	Компании	Наборы
Характеристики команды	-0,00035	[-0,00099; 0,00029]	[-0,00116; 0,00057]
География	0,00060	[-0,00099; 0,00214]	[-0,00142; 0,00232]
Тематические теги	0,00510	[0,00179; 0,00851]	[0,00163; 0,00808]
Краткое описание	0,00051	[-0,00035; 0,00144]	[-0,00039; 0,00110]
География, теги и описание совместно	0,00609	[0,00251; 0,00984]	[0,00204; 0,00964]
CatBoost против ЛР на одинаковых признаках	0,00146	[-0,00054; 0,00331]	[-0,00025; 0,00331]
Полная модель против постоянного прогноза	0,00525	[0,00104; 0,00955]	[0,00130; 0,00954]
Полная модель против модели с тегами	0,00099	[-0,00024; 0,00223]	[-0,00008; 0,00197]
Исключение тегов из полной модели	0,00450	[0,00147; 0,00763]	[0,00135; 0,00723]
Исключение описания из полной модели	0,00051	[-0,00010; 0,00115]	[0,00008; 0,00086]
Исключение страны из полной модели	0,00040	[-0,00063; 0,00138]	[-0,00082; 0,00148]
Исключение команды из полной модели	-0,00023	[-0,00115; 0,00066]	[-0,00123; 0,00082]

Таблица 7.4: Качество полной модели и вариантов с исключением одного блока; пять групповых повторов, подбор каждого варианта по LogLoss.

Модель	LogLoss	AP	ROC-AUC
ЛР: все блоки признаков	0,2958	0,1402	0,6154
ЛР: все блоки без тегов	0,3003	0,1110	0,5602
ЛР: все блоки без описания	0,2963	0,1377	0,6120
ЛР: все блоки без страны	0,2962	0,1384	0,6100
ЛР: все блоки без команды	0,2956	0,1412	0,6147

Изменение ошибки при добавлении признаков и смене модели

УС: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.




Парные разности потерь усреднены по пяти повторам с разделением наборов УС. Отрезки — центральные 95% из 2000 повторных выборок целых наборов при фиксированных прогнозах; переобучение не учтено.
Источник: расчёты автора по выгрузкам УС с Kaggle.

Рисунок 7.2: Парные изменения LogLoss и условные 95%-ные границы при повторной выборке целых наборов УС. Переобучение моделей не учтено.

нестабильные оценки, поэтому число наборов с положительной разностью не используется как формальный тест.

Добавление тегов: различия между наборами УС

УС: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.



Средняя парная разность пяти групповых повторов внутри набора. Размер точки связан с числом компаний. Малые наборы дают особенно нестабильные оценки; точки не являются независимыми повторными экспериментами. Источник: расчёты автора по выгрузкам УС с Kaggle.

Рисунок 7.3: Средняя парная разность LogLoss модели с тегами и модели с командой внутри каждого набора. Указаны размеры групп; положительное значение соответствует улучшению.

7.4 Ранжирование редкого исхода и веса классов

AP модели с тегами равна 0,1353. В её верхней десятой части списка положительный исход имеют 14,59% компаний; подъём относительно общей частоты составляет 1,6341. Для полной модели соответствующая точность равна 15,11%. Отбор выполняется отдельно в каждой проверочной части, а числа найденных и отобранных компаний суммируются внутри повтора.


Таблица 7.5: Качество ранжирования, среднее пяти групповых повторов. Р и R получены из суммарных чисел отобранных компаний и найденных исходов; Lift равен Р, делённой на частоту положительного класса.

Модель	AP	ROC-AUC	P@10%	R@10%	Lift@10%
ЛР: набор, возраст и команда	0,1017	0,5220	0,0920	0,1038	1,0303
ЛР: команда и география	0,1087	0,5549	0,1022	0,1154	1,1446
ЛР: команда и теги	0,1353	0,6052	0,1459	0,1647	1,6341
ЛР: команда и краткое описание	0,1037	0,5396	0,0912	0,1029	1,0213
ЛР: все блоки признаков	0,1402	0,6154	0,1511	0,1706	1,6926
ЛР: все блоки, подбор по AP	0,1363	0,6082	0,1414	0,1596	1,5832
ЛР: все блоки, веса классов	0,1386	0,6185	0,1531	0,1728	1,7144
CatBoost: набор, возраст и команда	0,1109	0,5286	0,1002	0,1132	1,1226

Для сравнения весов классов оба варианта полной модели подбирались по AP. Без весов получены AP 0,1363 и P@10% 0,1414; с весами — 0,1386 и 0,1531. Это сравнение относится к выбранной процедуре настройки. Отдельная основная полная модель подбирается по LogLoss и отвечает задаче вероятностного прогнозирования.

Точность и полнота при редком положительном исходе

УС: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.




Кривые отдельных частей перенесены на общую сетку полноты ступенчатой интерполяцией и усреднены с весами по размеру частей. AP усреднена отдельно; это не площадь под нарисованной кривой. Обе модели для проверки весов подбираются по AP.
 Источник: расчёты автора по выгрузкам УС с Kaggle.

Рисунок 7.4: PR-кривые, усреднённые по отдельным проверочным частям пяти групповых повторов. Прогнозы разных моделей для построения исходных кривых не объединяются. AP в легенде усреднена отдельно.

Преобладание отрицательных исходов среди отобранных компаний ожидаемо при ред-

Доля положительных исходов среди 10% наибольших оценок

YC: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.



В каждой части отобраны верхние 10%. Точность рассчитана по сумме отобранных и найденных компаний внутри повтора; затем усреднена по пяти повторам. Метрика оценивает качество ограниченного по объёму отбора, а не калибровку вероятностей.

Источник: расчёты автора по выгрузкам YC с Kaggle.

Рисунок 7.5: Доля положительных исходов среди верхних 10% оценок в каждой проверочной части, с объединением счётчиков внутри повтора. Пунктир — общая частота исхода.


ком событии и само по себе не исключает полезности предварительного ранжирования. Практическая полезность здесь не оценивалась: неизвестны стоимость проверки компании и последствия ошибок. Модель не обоснована как самостоятельный инструмент инвестиционного решения.

7.5 Соответствие вероятностей наблюдаемым частотам

На Рисунке 7.6 средние вероятности сопоставлены с частотами исхода в пяти группах первого группового повтора. Границы квантилей определены отдельно для каждой модели; число компаний и положительных исходов сохранено в `calibration_bins.csv`. График позволяет увидеть крупные расхождения, но пять агрегированных точек могут скрывать локальную ошибку. Поскольку использованы пересекающиеся обучающие выборки и один повтор, совпадение точек с диагональю не доказывает калибровку на новых данных.

Предсказанные вероятности и наблюдаемые частоты исхода

УС: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.



Первый повтор с разделением наборов УС; только проверочные прогнозы. Точки — группы примерно равного размера по вероятности, границы определены отдельно для каждой модели. Линии соединяют точки; дополнительная калибровка моделей не выполнялась.

Источник: расчёты автора по выгрузкам УС с Kaggle.

Рисунок 7.6: Средние вероятности и наблюдаемые частоты в пяти квантильных группах проверочных прогнозов. Взвешенная модель исключена; дополнительная калибровка не выполнялась.

7.6 Интерпретация тематических меток

Таблица 7.6 и Рисунок 7.7 относятся к модели с тегами, непосредственно участвующей в обнаружении основного сигнала. Показаны двенадцать самых частых меток среди компаний с известным исходом. Знак коэффициента описывает условное изменение логарифма шансов в этой регуляризованной модели. Доля положительных коэффициентов отражает стабильность знака по обучающим частям, а не вероятность истинности гипотезы.

Таблица 7.6: Частые теги: число компаний n , число положительных исходов n_+ и распределение коэффициентов по 25 внешним групповым обучающим частям. Диапазон 10–90% не является доверительным интервалом.

Метка	n	n_+	Медиана β	10–90%	$\beta > 0$, %
SaaS	809	100	0,260	[0,170; 0,318]	100
B2B	707	74	-0,043	[-0,113; 0,055]	28
Fintech	553	38	-0,289	[-0,370; -0,200]	0
Developer Tools	336	46	0,107	[0,038; 0,192]	100
Artificial Intelligence	267	29	0,033	[0,000; 0,104]	88
Marketplace	240	13	-0,306	[-0,399; -0,231]	0
Machine Learning	171	22	0,167	[0,039; 0,279]	96
E-commerce	150	15	0,022	[-0,047; 0,119]	68
Climate	134	12	0,005	[-0,073; 0,040]	52
AI	129	8	-0,245	[-0,274; -0,200]	0
Consumer	114	6	-0,166	[-0,253; -0,100]	0
Generative AI	114	13	0,066	[-0,200; 0,107]	76

Пересечение тематических меток и их связь с другими характеристиками не позволяют трактовать коэффициенты изолированно. Даже стабильный знак не доказывает, что изменение тега изменит исход компании. Проверочная полезность установлена для блока, а индивидуальный вклад каждой метки не проверялся отдельным экспериментом.


Метки SaaS (медиана 0,260), Developer Tools (медиана 0,107) имеют положительный коэффициент во всех 25 обучающих частях. Метки Fintech (медиана -0,289), Marketplace (медиана -0,306) имеют отрицательный коэффициент во всех 25 обучающих частях. Различия знаков у близких по смыслу обозначений, например AI и Artificial Intelligence, дополнительно показывают зависимость интерпретации от таксономии и сочетания меток. Изменение формулировки карточки не является установленным способом изменить исход компании.

7.7 Вспомогательное объяснение CatBoost

Для CatBoost средние модули SHAP получены на проверочных компаниях первого группового повтора. Используется та же групповая схема, что и в основных результатах. Величина вклада объясняет вариацию выхода конкретной модели; её нельзя сопоставлять с

Коэффициенты частых тегов в логистической модели

YC: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.




12 самых частых меток в выборке с известным исходом. Медиана и 10–90%-ный диапазон коэффициентов по 25 групповым обучающим частям; это не доверительные интервалы и не причинные эффекты.
Источник: расчёты автора по выгрузкам YC с Kaggle.

Рисунок 7.7: Медианы и 10–90%-ные диапазоны коэффициентов частых тегов. Отбор показанных меток основан на частоте, без учёта исхода.

приростом LogLoss от добавления блока. CatBoost не использует теги, поэтому его объяснение не заменяет анализа тематических характеристик.

Вклад признаков в проверочные прогнозы CatBoost

УС: 3 046 компаний, активных 13.07.2023; статус известен в августовской версии 2026 года.



CatBoost с набором, возрастом и командой; первый групповой повтор. Для каждой компании объясняется модель, не обучавшаяся на ней. Модуль SHAP не показывает направление связи, причинный эффект или улучшение проверочного качества.

Источник: расчёты автора по выгрузкам УС с Kaggle.

Рисунок 7.8: Средние абсолютные вклады SHAP в проверочные прогнозы CatBoost, первый групповой повтор. Единица измерения — логарифм шансов.

7.8 Чувствительность к составу совокупности и исхода

Без ИК12 остаются 3 045 компаний с известным исходом. Проверка без публичных компаний включает 3 039 наблюдений и 265 поглощений. В обеих проверках заново построены разбиения, преобразования и модели; использовано пять групповых повторов. При исключении публичных компаний меняются и целевая постановка, и состав совокупности, поэтому это анализ чувствительности, а не прогноз конкурирующих событий.

Эти расчёты не восстанавливают статусы отсутствующих компаний. Границы 8,75–10,80%, полученные в EDA, относятся только к доле положительного класса при неизвестных исходах, а не к качеству моделей.

Таблица 7.7: Проверки чувствительности. Для модели с командой ΔL рассчитана относительно модели с набором и возрастом; для модели с тегами и полной — относительно модели с командой. Границы получены повторной выборкой целых наборов.

Выборка	n	Модель	LogLoss	AP	ΔL	Наборы: 95%
Основная	3046	ЛР: набор, возраст и команда	0,3019	0,1017	-0,00035	[-0,00116; 0,00057]
Основная	3046	ЛР: команда и теги	0,2968	0,1353	0,00510	[0,00163; 0,00808]
Основная	3046	ЛР: все блоки признаков	0,2958	0,1402	0,00609	[0,00204; 0,00964]
Без IK12	3045	ЛР: набор, возраст и команда	0,3017	0,1043	-0,00040	[-0,00105; 0,00034]
Без IK12	3045	ЛР: команда и теги	0,2965	0,1356	0,00522	[0,00188; 0,00802]
Без IK12	3045	ЛР: все блоки признаков	0,2955	0,1422	0,00620	[0,00217; 0,00955]
Без публичных	3039	ЛР: набор, возраст и команда	0,2968	0,0924	-0,00040	[-0,00079; -0,00001]
Без публичных	3039	ЛР: команда и теги	0,2918	0,1315	0,00503	[0,00200; 0,00773]
Без публичных	3039	ЛР: все блоки признаков	0,2910	0,1366	0,00581	[0,00213; 0,00900]

7.9 Выводы прогнозного эксперимента

Добавление тематических меток изменило LogLoss относительно модели с командой на 0,00510 в сторону уменьшения. Условный диапазон повторной выборки наборов целиком находится выше нуля. Это оценка блока признаков в выбранной процедуре обучения, а не доказательство причинного действия тегов.

Преимущество полной модели перед моделью с тегами не установлено устойчиво: условный диапазон по наборам включает ноль.

Среднее улучшение от добавления тегов сохраняется при исключении IK12 и публичных компаний. Проверки чувствительности используют ту же исходную базу и не являются внешней валидацией.

При одинаковом подборе по AP взвешенная модель имеет среднюю AP выше, а точность верхней десятой части выше, чем вариант без весов. Эти наблюдаемые различия не трактуются как доказательство универсального эффекта взвешивания.

Все сравнения остаются разведочными: состав моделей уточнялся после изучения данной совокупности. Диапазоны по повторным выборкам условны относительно сохранённых прогнозов. Обнаруженные связи нуждаются в проверке на независимо собранной совокупности и новом календарном периоде.

8 Заключение

8.1 Выполненные задачи

- 1 Рассмотрены подходы к определению результата молодой компании и разграничены прогнозирование, описание зависимостей и причинная интерпретация.
- 2 Сформирована исходная группа активных компаний, разделены ранние признаки и поздние статусы. Происхождение файлов описано в разделе 4, состав когорты и результаты сопоставления — в разделе 5. Для позднего файла документировано основание отнесения к августовской версии 2026 года.
- 3 Выполнен разведочный анализ полноты, состава и распределений признаков; отдельно исследованы неизвестные исходы и группа ИК12.
- 4 Проведена вложенная проверка постоянного прогноза, логистических моделей и CatBoost. В каждой из двух схем выполнено пять повторов; разнообразие групповых разбиений проверено отдельно.
- 5 Оценены добавление и исключение блоков признаков, сравнение полной модели с моделью с тегами, разброс между наборами и условные границы при повторных выборках компаний и наборов.
- 6 Согласованы метрики и PR-графики, проверены веса классов при одинаковом критерии настройки, интерпретированы коэффициенты частых тегов. Проведено повторное обучение без ИК12 и без публичных компаний.

8.2 Основные результаты

Исходная группа включает 3 110 компаний, активных 13 июля 2023 года. В августовской версии 2026 года известны статусы 3 046 компаний; 272 имеют положительную метку, что составляет 8,93%. Из них 265 поглощены, поэтому целевая метка преимущественно характеризует поглощение и не является общей мерой экономической успешности.

Из 64 неизвестных исходов 43 относятся к ИК12. Поэтому почти полное сопоставление остальных компаний не обеспечивает представительности для этого нестандартного набора. Границы 8,75–10,80% характеризуют возможную общую долю положительных исходов, но не диапазон качества моделей.

Описательное сравнение показало перекрытие распределений размера команды: медианы равны десяти сотрудникам у сохранивших активность, пяти — у ставших неактивными и восьми — у поглощённых компаний. Корреляция Спирмена между возрастом и размером команды составляет 0,58. Эти результаты описывают выборку, не устанавливая причинных эффектов или дополнительного прогнозного вклада.

LogLoss постоянного прогноза составляет 0,3011, полной логистической модели — 0,2958; относительное снижение равно 1,75%. ROC-AUC полной модели равна 0,6154, AP — 0,1402. Результат характеризует небольшой прогностический сигнал в рассматриваемых открытых сведениях.

Добавление тематических меток изменило LogLoss относительно модели с командой на 0,00510 в сторону уменьшения. Условный диапазон повторной выборки наборов целиком находится выше нуля. Это оценка блока признаков в выбранной процедуре обучения, а не доказательство причинного действия тегов.

Преимущество полной модели перед моделью с тегами не установлено устойчиво: условный диапазон по наборам включает ноль.

Среднее улучшение от добавления тегов сохраняется при исключении ИК12 и публичных компаний. Проверки чувствительности используют ту же исходную базу и не являются внешней валидацией.

При одинаковом подборе по AP взвешенная модель имеет среднюю AP выше, а точность верхней десятой части выше, чем вариант без весов. Эти наблюдаемые различия не трактуются как доказательство универсального эффекта взвешивания.

В верхней десятой части списка модели с тегами положительную метку имеют 14,59% компаний, Lift составляет 1,6341. Такой результат описывает обогащение отобранной группы редким исходом; он не является оценкой доходности или готовой рекомендацией по инвестированию. Устойчивость знаков коэффициентов частых тегов относится к выбранной регуляризованной модели и не заменяет отдельной проверки полезности каждой метки.

8.3 Ограничения исследования

- Выборка ограничена компаниями УС, представленными в сторонней выгрузке и активными в июле 2023 года. Результаты не описывают все компании акселератора или весь рынок.
- Поздний файл скачан автором в середине августа 2026 года. Дата 01.08.2026 обозначает предполагаемую августовскую версию по графику обновления источника; номер версии

и точные моменты сбора строк не сохранены. Статусы могут обновляться с задержкой.

- Два среза не раскрывают даты событий, промежуточные состояния, условия сделок или доходность. Интервал сопоставления общий для компаний; различие возраста не означает различной длительности последующего наблюдения.
- Неизвестные исходы распределены неравномерно. Исключение IK12 в дополнительном анализе не восстанавливает статусы отсутствующих компаний.
- Признаки измерены в июле 2023 года, а не при основании или поступлении в УС. Теги отражают как деятельность, так и правила ведения каталога.
- Внешние части относятся к вложенной проверке внутри данной совокупности. Повторы используют одни и те же компании; условные диапазоны не учитывают переобучение и весь процесс выбора моделей.
- Набор моделей и проверок уточнялся после изучения данных. Сравнения нескольких блоков и интерпретации отдельных тегов являются разведочными; формальные подтверждающие тесты не проводились.

8.4 Выводы и рекомендации

Исследование оценивает полезность блоков доступных сведений для конкретного наблюдаемого исхода. Необнаруженное улучшение в отдельной конфигурации не доказывает бесполезности признака во всех моделях или для других исходов. При сравнении сложной и простой модели следует учитывать размер и устойчивость выигрыша, а не только минимальную среднюю ошибку.

Для предварительного ранжирования необходимы независимая проверка качества и калибровки, определение стоимости проверки компании и последствий ошибок. Само по себе преобладание отрицательных исходов среди отобранных компаний при редком событии не исключает практической полезности. Доказательство причинности не обязательно для прогнозного ранжирования, но необходимо для рекомендаций предпринимателю изменить состав команды или позиционирование ради улучшения результата.

Следующий эксперимент следует зафиксировать до наблюдения новых исходов: определить дату формирования признаков, горизонт, набор компаний, модели, метрики и правила отбора. Его нужно проверить на новом календарном периоде, а затем отдельно на компаниях

вне УС. После изучения всей текущей совокупности выделение части этих же данных нельзя представлять как полностью независимую подтверждающую проверку.

Данные с датами поглощений, выхода на биржу, прекращения деятельности и финансирования позволят исследовать время до события и конкурирующие исходы. Для текущей постановки с общим поздним срезом бинарная классификация остаётся допустимой; её ограничения связаны прежде всего со смыслом статуса, качеством регистрации и переносимостью результата.

9 Описание применения генеративных моделей

При подготовке работы использовался программный агент OpenAI Codex компании OpenAI. На раннем этапе переработки применялась модель GPT-5; при финальной критической вычитке и исправлении исследования — GPT-6. Работа с агентом велась через клиент Codex с доступом к файлам проекта и возможностью запуска программ анализа. Описание продукта доступно по адресу <https://openai.com/codex/>. Период использования при переработке работы — с 12 августа по 18 сентября 2026 года.

Генеративные модели участвовали в содержательной и технической переработке исследования. Их применение охватывало следующие задачи:

- 1 критический разбор первоначального дизайна исследования и выявление расхождений между текстом, программным кодом и данными;
- 2 подготовку вариантов структуры разделов, уточнение формулировок и научно-деловое редактирование текста;
- 3 рефакторинг программ подготовки данных, разведочного анализа и прогнозного эксперимента;
- 4 разработку и редактирование программ построения графиков;
- 5 поиск ошибок в обработке дат набора, сезонов, пропусков и последующих статусов;
- 6 подготовку автоматических тестов, запуск вычислений и проверку сборки документа в системе L^AT_EX.
- 7 на финальном этапе — критическое чтение текста курсовой работы, анализ последовательности исследования и выявление расхождений между постановкой, программным кодом, расчётами и выводами.

Модель получала запросы на русском языке с указанием изменяемых файлов, требований к исследованию и замечаний научного руководителя. Сгенерированные предложения не принимались автоматически. Численные утверждения сверялись с сохранёнными Таблицами и отчётами, изменения программного кода проверялись тестами, а ссылки на литературу — по библиографическим данным и первичным публикациям. После внесения изменений повторно запускались подготовка данных, построение графиков, тесты и сборка документа.

Использование модели ускорило поиск несогласованностей и техническую переработку проекта, однако потребовало обязательной проверки. В ходе работы модель предлагала

чрезмерно уверенные интерпретации описательных связей, допускала неудачные формулировки и не всегда правильно учитывала контекст всей работы. Такие предложения исправлялись или исключались. Генеративная модель не использовалась как источник эмпирических данных и не заменяла расчёты программ анализа.

Применение агента помогло обнаружить почти совпадающие групповые повторы, различия в агрегировании метрик и несогласованные интерпретации.

Автор определял постановку исследования, принимал решения о включении методов и результатов, проверял предложенные изменения и несёт полную ответственность за содержание работы. Описание использования модели составлено в соответствии с требованием НИУ ВШЭ раскрывать цели, конкретную технологию, способ и результат её применения [24].

Список литературы

- [1] Albert V. Bruno, Edward F. McQuarrie и Carol G. Torgrimson. «The evolution of new technology ventures over 20 years: Patterns of failure, merger, and survival». В: *Journal of Business Venturing* 7.4 (1992), с. 291—302. DOI: [10.1016/0883-9026\(92\)90003-A](https://doi.org/10.1016/0883-9026(92)90003-A).
- [2] CatBoost developers. *ShapValues*. URL: <https://catboost.ai/docs/en/concepts/shap-values> (дата обр. 13.09.2026).
- [3] GetInvestor. *Crunchbase — что это такое и как пользоваться*. 2024. URL: <https://get-investor.ru/crunchbase-chem-polezen-startapu> (дата обр. 30.01.2025).
- [4] Paul A. Gompers, Will Gornall, Steven N. Kaplan и Ilya A. Strebulaev. *How Do Venture Capitalists Make Decisions?* Working Paper 22587. National Bureau of Economic Research, 2016. DOI: [10.3386/w22587](https://doi.org/10.3386/w22587). URL: <https://www.nber.org/papers/w22587>.
- [5] Kaggle. *Y Combinator Companies Dataset*. 2026. URL: <https://www.kaggle.com/datasets/nitishraj/ycombinatorcompanies> (дата обр. 14.09.2026).
- [6] Kaggle. *Y Combinator Directory*. 2023. URL: <https://www.kaggle.com/datasets/miguelcorraljr/y-combinator-directory> (дата обр. 14.09.2026).
- [7] Ulrich Kaiser и Johan Moritz Kuhn. *The Value of Publicly Available, Textual and Non-textual Information for Startup Performance Prediction*. Discussion Paper 13029. IZA Institute of Labor Economics, 2020. URL: <https://docs.iza.org/dp13029.pdf>.
- [8] Ulrich Kaiser и Johan Moritz Kuhn. «The Value of Publicly Available, Textual and Non-textual Information for Startup Performance Prediction». В: *Journal of Business Venturing Insights* 14, e00179 (2020). DOI: [10.1016/j.jbv.2020.e00179](https://doi.org/10.1016/j.jbv.2020.e00179).
- [9] Sayash Kapoor и Arvind Narayanan. «Leakage and the reproducibility crisis in machine-learning-based science». В: *Patterns* 4.9, 100804 (2023). DOI: [10.1016/j.patter.2023.100804](https://doi.org/10.1016/j.patter.2023.100804).
- [10] Marc Mangel и Francisco J. Samaniego. «Abraham Wald’s Work on Aircraft Survivability». В: *Journal of the American Statistical Association* 79.386 (1984), с. 259—267. DOI: [10.1080/01621459.1984.10478038](https://doi.org/10.1080/01621459.1984.10478038).
- [11] Alexandru Niculescu-Mizil и Rich Caruana. «Predicting Good Probabilities with Supervised Learning». В: *Proceedings of the 22nd International Conference on Machine Learning*. 2005, с. 625—632. DOI: [10.1145/1102351.1102430](https://doi.org/10.1145/1102351.1102430).

- [12] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush и Andrey Gulin. *CatBoost: unbiased boosting with categorical features*. 2019. arXiv: [1706.09516](https://arxiv.org/abs/1706.09516). URL: <https://arxiv.org/abs/1706.09516> (дата обр. 13.09.2026).
- [13] Greg Ross, Sanjiv Ranjan Das, Daniel Sciro и Hussain Raza. «CapitalVX: A machine learning model for startup selection and exit prediction». В: *The Journal of Finance and Data Science* 7 (2021), с. 94—114. DOI: [10.1016/j.jfds.2021.04.001](https://doi.org/10.1016/j.jfds.2021.04.001).
- [14] scikit-learn developers. *Metrics and scoring: quantifying the quality of predictions*. URL: https://scikit-learn.org/stable/modules/model_evaluation.html (дата обр. 13.09.2026).
- [15] scikit-learn developers. *Nested versus non-nested cross-validation*. URL: https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html (дата обр. 13.09.2026).
- [16] SHAP developers. *Be careful when interpreting predictive models in search of causal insights*. URL: https://shap.readthedocs.io/en/latest/example_notebooks/overviews/Be%20careful%20when%20interpreting%20predictive%20models%20in%20search%20of%20causal%20insights.html (дата обр. 13.09.2026).
- [17] Boris Sharchilev, Michael Roizner, Andrey Rumyantsev, Denis Ozornin, Pavel Serdyukov и Maarten de Rijke. «Web-based Startup Success Prediction». В: *Proceedings of the 27th ACM International Conference on Information and Knowledge Management*. ACM, 2018. DOI: [10.1145/3269206.3272011](https://doi.org/10.1145/3269206.3272011). URL: <https://staff.fnwi.uva.nl/m.derijke/wp-content/papercite-data/pdf/sharchilev-web-based-2018.pdf>.
- [18] Galit Shmueli. «To Explain or to Predict?» В: *Statistical Science* 25.3 (2010), с. 289—310. DOI: [10.1214/10-STS330](https://doi.org/10.1214/10-STS330).
- [19] Wikipedia. *Kaggle*. 2024. URL: <https://ru.wikipedia.org/wiki/Kaggle> (дата обр. 30.01.2025).
- [20] Wikipedia. *Разведочный анализ данных*. 2024. URL: https://ru.wikipedia.org/wiki/%D0%A0%D0%B0%D0%B7%D0%B2%D0%B5%D0%B4%D0%BE%D1%87%D0%BD%D1%8B%D0%B9_%D0%B0%D0%BD%D0%B0%D0%BB%D0%B8%D0%B7_%D0%B4%D0%B0%D0%BD%D0%BD%D1%8B%D1%85 (дата обр. 30.01.2025).
- [21] Y Combinator. *The YC Startup Directory*. URL: <https://www.ycombinator.com/companies> (дата обр. 10.09.2026).

- [22] Y Combinator. *Y Combinator*. 2025. URL: <https://www.ycombinator.com/> (дата обр. 10.02.2025).
- [23] ВТБ. *Что такое стартап*. 2024. URL: <https://vtb.ru/articles/что-такое-startap/> (дата обр. 30.01.2025).
- [24] Национальный исследовательский университет «Высшая школа экономики». *Правила использования искусственного интеллекта студентами*. 2026. URL: https://www.hse.ru/studyspravka/ai_guidelines_pps (дата обр. 17.09.2026).

А Первоначальный план проекта

План отражает первоначальную постановку. Гипотезы Н1–Н8 и период 2023–2025 годов не являются задачами выполненного прогнозного эксперимента.

Таблица А.1: Календарный план проекта (25.01.2026 – 01.04.2026)

Этап	Неделя / Период	Основные задачи	Результат
Этап 1: Подготовка данных и EDA	Неделя 1 25.01–31.01	Сбор данных (Kaggle); настройка окружения; слияние источников; обработка пропусков	Объединенные датасеты
	Неделя 2 01.02–07.02	Создание производных признаков (бинарный статус, тип основателей); EDA: распределения, пропуски	Датасет А и В + ноутбук
	Неделя 3 08.02–14.02	Анализ категориальных признаков; визуализация батчей, отраслей, стран	EDA-отчет с графиками
Этап 2: Анализ предикторов	Неделя 4 15.02–21.02	Проверка гипотез Н1–Н4: соло vs команда, B2B vs Consumer, сезон батча, лаконичность описания	Графики и статистические тесты
	Неделя 5 22.02–28.02	Проверка гипотез Н5–Н8: количество тегов, найм, география, стадия развития	Полный набор визуализаций
	Неделя 6 01.03–07.03	Корреляционный анализ; анализ динамики 2023–2025; матрица переходов	Корреляционная матрица + выводы
Этап 3: Оформление	Неделя 7 08.03–14.03	Написание отчета: введение, описание данных, методология	Черновик курсовой работы
	Неделя 8 15.03–21.03	Написание отчета: результаты, выводы, оформление графиков	Полный текст работы
	Финал 22.03–01.04	Проверка оформления; создание презентации; финализация	Готовый проект к защите